



Stima della cardinalità nei flussi di dati distribuiti:

merge e compatibilità semantica
degli algoritmi di sketching

Daniele Ferroli

April 23, 2026

Università degli Studi di Udine




where (ϵ, δ) -approximation means

$$\forall \epsilon \exists \delta : \mathbb{P}[|F_0 - \hat{F}_0| > \epsilon F_0] < \delta$$

- sicurezza di rete / monitoraggio / telemetria
- conteggio di like, visitatori unici, page ranking
- DBMS
- ...

- implementazione degli algoritmi PC, LL, HLL, HLL++
- framework sperimentale modulare, estendibile
- analisi empirica sistematica
 - ▶ focus in particolare sul merge


Merge



- **assunzioni:** stessi parametri algoritmici, hash, seed
- **motivazioni:** sistemi distribuiti eterogenei

- implementazione degli algoritmi PC, LL, HLL, HLL++
- framework sperimentale modulare, estendibile
- analisi empirica sistematica
 - ▶ focus in particolare sul merge
 - classificazione operativa
 - degradazione dovuta a normalizzazione
 - ...

Sketch come struttura dati dinamica



- **update:** operazione $O(1)$
- **query:** come funziona
- **vincoli:**
 - ▶ unbiased ($F_0 \approx \hat{F}_0$)
 - ▶ update time $O(1)$
 - ▶ small memory ...


<u>lower bound</u>	<u>upper bound</u>
$\Omega(\epsilon^{-2} + \log N)$	$O(m \cdot \log N)$
$\Theta(\epsilon^{-2} + \log N)$	

Diagramma da fare

- HyperLogLog
- HyperLogLog++
- UltraLogLog
- ...

Ci sono 3 casi valid, invalid, recoverable

Framework



Da inserire la tabella dell'esempio

- come è fatto
- perché binario e compresso
- quanto occupa
- ...

alcuni con cardinalità fissata e rho

max 3 grafici

ciò di cui ho parlato

- dataset sintetico vs empirico
- merge non pairwise con topologie diverse
- varianti di sketch su altri problemi
-

Grazie per l'attenzione

Domande ?