

Stima della cardinalità nei flussi di dati distribuiti


merge e compatibilità semantica
degli algoritmi di sketching

Daniele Ferroli

29 aprile 2026

Università degli Studi di Udine

Relatore: Prof. Gabriele Puppis




$\hat{F}_0$ is a (ϵ, δ) -approximation of F_0 if

$$0 < \epsilon, \delta < 1 : \mathbb{P}[|F_0 - \hat{F}_0| > \epsilon F_0] < \delta$$

- sicurezza di rete / monitoraggio / telemetria
- **conteggio di like**, visitatori unici, page ranking
- ottimizzazione di query nei DBMS
- ...

- implementazione degli algoritmi Probabilistic Counting, LogLog, HyperLogLog, HyperLogLog++
- framework sperimentale modulare, estendibile
- analisi empirica sistematica
 - ▶ focus in particolare sul merge

Merge



- **assunzioni:** sui parametri algoritmici, hash, seed
- **motivazioni:** sistemi distribuiti eterogenei

- implementazione degli algoritmi Probabilistic Counting, LogLog, HyperLogLog, HyperLogLog++
- framework sperimentale modulare, estendibile
- analisi empirica sistematica
 - ▶ focus in particolare sul merge
 - classificazione operativa
 - **degradazione** dovuta a normalizzazione
 - ...

Sketch come struttura dati dinamica



- **update:** aggiorna la struttura dati elemento per elemento
- **query:** restituisce la stima
- **vincoli:**
 - ▶ unbiased ($F_0 \approx \hat{F}_0$)
 - ▶ update time $O(1)$
 - ▶ small memory ...

Sketch come struttura dati dinamica



- **update:** aggiorna la struttura dati elemento per elemento
- **query:** restituisce la stima
- **vincoli:**
 - ▶ unbiased ($F_0 \approx \hat{F}_0$)
 - ▶ update time $O(1)$
 - ▶ small memory ...

lower bound
 $\Omega(\log N)$

trivial upper bound
 $O(m \cdot \log N)$

in bits, where:

m = # of distinct elements

N = # of elements in the universe

Sketch come struttura dati dinamica



- **update:** aggiorna la struttura dati elemento per elemento
- **query:** restituisce la stima
- **vincoli:**
 - ▶ unbiased ($F_0 \approx \hat{F}_0$)
 - ▶ update time $O(1)$
 - ▶ small memory ...

lower bound
 $\Omega(\log N)$

trivial upper bound
 $O(m \cdot \log N)$


in bits, where:

m = # of distinct elements

N = # of elements in the universe

$$\Theta(\epsilon^{-2} + \log N)$$

Sketch LogLog



update:

$$M[r] \leftarrow \max(M[r], \psi(w))$$

query:

$$\hat{F}_0 = \alpha_m \cdot m \cdot 2^A$$

- HyperLogLog
- HyperLogLog++
- UltraLogLog
- ...

media armonica, correzione del bias
sparse vs dense, **correzioni empiriche**
stima più efficiente, registri più informativi

Compatibilità semantica del merge

Il merge è corretto solo se le due sketch descrivono i dati con la **stessa semantica**: algoritmo, parametri e hash devono essere compatibili.

valid	recoverable	invalid
Stessa semantica su entrambe le sketch.	Non direttamente compatibile, ma normalizzabile.	Non esiste un merge semanticamente corretto.
Azione: merge diretto.	Azione: riduzione e merge.	Azione: rifiuto.

Dataset

- **dataset**: diviso in p partizioni
- **partizione**: n elementi totali, d elementi distinti, organizzazione in blocchi di dimensione $\rho = \frac{n}{d}$

	blocco 1			blocco 2			blocco 3			blocco 4		
t	1	2	3	4	5	6	7	8	9	10	11	12
x_t	a	a	a	b	a	b	c	a	c	d	b	c
b_t	1	0	0	1	0	0	1	0	0	1	0	0
$F_0(t)$	1	1	1	2	2	2	3	3	3	4	4	4


Tabella 1: Partizione con $n = 12$, $d = 4$ e $\rho = n/d = 3$

esempio


un dataset **binario** e **compresso** da 50 partizioni, con $n = 10^7$ occupa $\approx 1.7GB$!!
aumentare di un ordine di grandezza $n \Rightarrow$ **10x** sulla dimensione

- Cardinalità stimata rispetto alla cardinalità reale
- Confronto tra diverse precisioni per lo stesso algoritmo
- Caso *recoverable* durante un operazione di merge

Cardinalità stimata rispetto alla cardinalità reale





scala lineare



scala logaritmica




$$n = 10^7, \rho \in \{1, 2, 5, 10, 20, 50, 100\}, \text{seed} = 21041998.$$

Confronto tra diverse precisioni per lo stesso algoritmo



$$p \in \{1, 10, 100\}$$

Caso recoverable durante un operazione di merge



$$\rho \in \{1, 10, 100\}$$

Framework modulare ed estendibile

Accuratezza HLL++ risulta l'algoritmo migliore

Merge distribuito caso omogeneo = seriale

Compatibilità necessario l'uso degli stessi parametri per il merge

Recoverable necessario normalizzare $\implies$ degrado stima

- dataset sintetico vs reale
- merge non pairwise con topologie diverse
- varianti di sketch su altri problemi:
 - ▶ membership
 - ▶ moments-frequency
- ...

Grazie per l'attenzione

Domande ?