



UNIVERSITÀ DEGLI STUDI DI UDINE

DIPARTIMENTO DI SCIENZE MATEMATICA, INFORMATICHE E FISICHE

TESI MAGISTRALE IN INFORMATICA

ALGORITMI E RAGIONAMENTO AUTOMATICO

UNO STUDIO SUGLI ALGORITMI DI SKETCHING PER LA STIMA DELLA CARDINALITÀ

RELATORE

PROF. GABRIELE PUPPIS

LAUREANDO MAGISTRALE

DANIELE FERROLI

MATRICOLA

137357

ANNO ACCADEMICO

2024-2025

“DA SCRIVERE”
— RENE DESCARTES

Indice

NOTAZIONI E CONCETTI PRELIMINARI	I
1 INTRODUZIONE	3
2 BACKGROUND	5
2.1 Modello di stream di dati	5
2.2 Algoritmi di streaming	7
2.3 Funzioni di hash	9
2.4 Sketch	10
2.5 Stimatori	11
2.6 Metriche di errore	13
2.7 Famiglia di algoritmi per count-distinct	14
2.8 Altri obiettivi di sketching	15
2.9 Spazio e accuratezza	15
3 UN'ANALISI SULLO STATO DELL'ARTE	17
3.1 Obiettivo del problema e vincoli teorici	17
3.2 Sviluppo storico	18
3.2.1 Probabilistic Counting	18
3.2.2 LogLog	20
3.2.3 HyperLogLog	21
3.2.4 HyperLogLog++	24
3.3 Confronto sintetico tra gli approcci	26
3.4 Correzioni di range e riduzione del bias	27
3.5 Mergeabilità e scenari distribuiti	27
3.6 Estensioni oltre il count-distinct	28
3.6.1 Count-Min Sketch	28
3.6.2 Bloom Filter (membership)	29
4 IMPLEMENTAZIONE	31
4.1 Architettura del sistema	31
4.2 Dataset	32
4.2.1 Motivazione del formato	32
4.2.2 Struttura del file	33
4.2.3 Bitset di verità per $F_0(t)$	33
4.2.4 Indicizzazione e caricamento per partizione	34
4.2.5 Esempio	34
4.3 Generazione dataset	35
4.4 Interfacce comuni e hashing	35
4.4.1 Interfaccia base degli algoritmi	35
4.4.2 Hashing uniforme nel codice	36
4.5 Implementazione degli algoritmi	36

4.5.1	ProbabilisticCounting	36
4.5.2	LogLog	36
4.5.3	HyperLogLog	36
4.5.4	HyperLogLog++	37
4.5.5	Verifica dei domini parametrici	37
4.6	Framework di valutazione	37
4.6.1	Modalità normal, streaming, merge	37
4.6.2	Metriche implementate	38
4.6.3	Checkpoint in modalità streaming	39
4.6.4	Output CSV	39
4.7	CLI e orchestrazione sperimentale	41
4.7.1	CLI interattiva	41
4.7.2	Orchestrazione batch	41
4.8	Seed e riproducibilità	42
4.9	Validazione e testing	42
4.9.1	Test algoritmici C++	42
4.9.2	Test framework	42
4.10	Scelte progettuali e limiti attuali	43
4.11	TODOs	43
5	RISULTATI SPERIMENTALI	45
5.1	Ambiente di test	45
5.1.1	Configurazione sperimentale	45
5.2	Selezione delle configurazioni migliori	46
5.3	Confronto tra i vari seed	46
5.4	Risultati streaming con le configurazioni ottimali	48
5.4.1	Stima media nel tempo e transitorio iniziale	48
5.4.2	Varianza nel tempo	51
5.4.3	Metriche aggregate in modalità <i>normal</i>	51
5.5	Risultati merge con la configurazione ottimale	51
5.6	Discussione	53
5.7	TODOs	54
6	CONCLUSIONI	55
	BIBLIOGRAFIA	57
	RINGRAZIAMENTI	59

Notazioni e concetti preliminari

In questa sezione si raccolgono le notazioni utilizzate nel resto della tesi.

- \mathcal{U} : universo degli elementi.
- $S = \langle x_1, \dots, x_s \rangle$: stream di dati.
- $S_1 \cdot S_2$: concatenazione di due stream.
- $n = |\mathcal{U}|$: dimensione dell'universo.
- $f(a)$: frequenza di $a \in \mathcal{U}$.
- (a_t, Δ_t) : aggiornamento al tempo t , con chiave a_t e incremento Δ_t .
- $A_t[j]$: frequenza dell'elemento j dopo i primi t aggiornamenti.
- $A_0[j] = 0$: condizione iniziale del modello insertion-only.
- $f \in \mathbb{N}^{|\mathcal{U}|}$: vettore delle frequenze (componenti $f(a)$).
- $\|f\|_1 = \sum_{a \in \mathcal{U}} f(a)$: lunghezza totale della stream.
- F_k : frequency moments.
- F_0 : numero di distinti nella stream.
- \hat{F}_0 : stima di F_0 prodotta da un algoritmo.
- \bar{F}_0 : media dei valori veri su R run.
- $\tilde{\bar{F}}_0$: media delle stime su R run.
- (ε, δ) : parametri di accuratezza; ε è l'errore relativo ammesso e $1 - \delta$ è la probabilità di successo.
- m : memoria dello sketch (tipicamente espressa in bit); nelle sezioni su LogLog/HLL/HLL++ il numero di registri è indicato anch'esso con $m = 2^p$, quindi lo spazio complessivo dipende anche dalla larghezza di ciascun registro.
- M : stato interno dell'algoritmo di streaming (lo sketch).
- $\mathcal{K}(\cdot)$: procedura che costruisce uno sketch da una stream.
- V : dominio di uscita di una funzione di hash.
- $h : \mathcal{U} \rightarrow V$: funzione di hash.
- \mathcal{H} : famiglia di funzioni di hash.
- L : lunghezza in bit del valore hash (nel Capitolo 3 si assume $L = w$).
- w : numero di bit del valore hash (se $V = \{0, 1\}^w$).
- p : parametro di precisione; tipicamente $m = 2^p$.
- p' : precisione usata nella rappresentazione sparsa di HLL++.

- k_{sp} : numero di entry non nulle nella rappresentazione sparsa di HLL++.
- $\rho(\cdot)$: posizione del primo bit a 1 nel suffisso hash.
- $j(x)$: indice del registro selezionato dai $\log_2 m$ bit più significativi di $h(x)$.
- $w(x)$: suffisso di $h(x)$ usato per calcolare $\rho(w(x))$ nel registro $j(x)$.
- α_m : costante di normalizzazione dipendente da m .
- ϕ : costante di calibrazione di PCSA ($\phi \approx 0.77351$).
- V_0 : numero di registri a zero (in HLL/HLL++).
- w_{cm} : numero di colonne nel Count-Min Sketch.
- d : numero di righe/funzioni hash nel Count-Min Sketch.
- m_{bf} : numero di bit del Bloom filter.
- k_{bf} : numero di funzioni hash del Bloom filter.
- n_{ins} : numero di elementi inseriti in un Bloom filter.
- \mathcal{S} : spazio degli stati di uno sketch.
- \oplus : operatore di merge tra stati di sketch.
- R : numero di run (ripetizioni) sperimentali.
- σ : deviazione standard campionaria delle stime.
- $\widehat{\text{Var}}(\hat{F}_0)$: varianza campionaria delle stime su R run.
- $\hat{\sigma}$: deviazione standard campionaria ($\hat{\sigma} = \sqrt{\widehat{\text{Var}}(\hat{F}_0)}$).
- RE: errore relativo.
- RSE: relative standard error.
- RSE_{obs} : relative standard error osservata, definita come $\hat{\sigma} / \bar{F}_0$.
- $\text{Bias}(\hat{\theta})$: bias di uno stimatore.
- $\text{Var}(\hat{\theta})$: varianza di uno stimatore.
- $\widehat{\text{Bias}}(\hat{F}_0)$: stima empirica del bias su R run.
- AB: absolute bias.
- RB: relative bias.
- MRE: mean relative error.
- MAE: mean absolute error.
- RMSE: root mean squared error.

1

Introduzione

2

Background

Il modello che rappresenta i dati in input, a differenza di algoritmi più tradizionali, è chiamato *modello di stream di dati* (data stream model).

2.1 MODELLO DI STREAM DI DATI

Nel modello di stream i dati [1] arrivano in modo continuo; la stream può essere potenzialmente infinita. Rispetto all'utilizzo di un database tradizionale, non è possibile accumulare tutto in memoria o su disco e interrogare i dati. Gli elementi devono essere processati al volo oppure vengono persi.

Inoltre, la velocità con cui i dati arrivano non è controllata dal sistema (più stream possono arrivare a velocità e con formati diversi) e lo spazio di memoria disponibile è limitato. Eventuali archivi storici possono esistere, ma non sono pensati per rispondere a query online in tempi ragionevoli.

Iniziamo a definire formalmente gli elementi di una stream e come vengono processati.

Def. 2.1 (Stream di dati). Sia \mathcal{U} un universo di chiavi. Senza perdita di generalità, assumiamo $\mathcal{U} \subseteq \mathbb{N}$. Una *stream di dati* è una sequenza ordinata di elementi

$$S = \langle x_1, x_2, \dots, x_s \rangle,$$

dove ogni $x_i \in \mathcal{U}$ e s può essere molto grande o non noto a priori.

Per analizzare una stream è utile descriverla tramite le frequenze degli elementi.

Def. 2.2 (Frequenze). Data una stream S , la *frequenza* di un elemento $a \in \mathcal{U}$ è

$$f(a) = |\{i \mid x_i = a\}|.$$

La collezione delle frequenze può essere vista come un vettore $f \in \mathbb{N}^{|\mathcal{U}|}$.

Una volta definita la nozione di frequenza, si specifica il modello di aggiornamento con cui la stream viene osservata. Nel modello della stream dei dati esistono diverse tipologie di modelli [2]. In questa tesi adottiamo il seguente.

Def. 2.3 (Modello *insertion-only*). La stream è una sequenza di aggiornamenti del tipo (a_t, Δ_t) , con $a_t \in \mathcal{U}$ e $\Delta_t \geq 0$. Indichiamo con $A_t[j]$ la frequenza dell'elemento j dopo i primi t aggiornamenti; allora

$$A_t[j] = \begin{cases} A_{t-1}[j] + \Delta_t & \text{se } a_t = j, \\ A_{t-1}[j] & \text{altrimenti.} \end{cases}$$

con inizializzazione $A_0[j] = 0$ per ogni $j \in \mathcal{U}$.

Se la stream è una lista di valori, ogni elemento x_i può essere visto come un aggiornamento $(x_i, 1)$.

Esistono tuttavia modelli più generali. Nel *turnstile* sono ammessi anche aggiornamenti negativi, così che le frequenze possano aumentare o diminuire. Nel modello a *sliding window* si considerano solo gli ultimi W aggiornamenti della stream, scartando i più vecchi. Questi casi esulano dallo scopo della tesi, ma sono citati per completezza.

Fissato il modello, l'obiettivo principale della tesi è stimare la cardinalità dell'insieme dei distinti.

Def. 2.4 (Numero di distinti). Il *numero di distinti* nella stream S è

$$F_0 = |\{a \in \mathcal{U} \mid f(a) > 0\}|.$$

Più in generale, il numero di distinti è un caso particolare di una famiglia di misure note come *frequency moments*.

Def. 2.5 (Frequency moments). Per ogni $k \geq 0$, il *frequency moment* F_k è definito come

$$F_k = \sum_{a \in \mathcal{U}} f(a)^k.$$

In particolare, F_0 corrisponde al numero di distinti.

Poiché in streaming non possiamo calcolare esattamente F_0 mantenendo memoria sublineare, adottiamo misure di accuratezza probabilistiche. Per valutare la qualità di una stima si introduce la nozione di approssimazione con parametri di accuratezza e confidenza.

Def. 2.6 ((ε, δ) -approssimazione). Un algoritmo A è detto (ε, δ) -*approssimante* per F_0 se, per ogni stream, produce una stima \hat{F}_0 tale che

$$\Pr(|\hat{F}_0 - F_0| \leq \varepsilon F_0) \geq 1 - \delta,$$

dove la probabilità è rispetto alla randomizzazione interna dell'algoritmo [3]. La forma relativa è intesa per $F_0 > 0$; nel caso $F_0 = 0$ si richiede, in modo naturale, $\Pr(\hat{F}_0 = 0) \geq 1 - \delta$.

ESEMPIO. Con $\varepsilon = 0,05$ e $\delta = 0,01$, l'algoritmo deve restituire una stima entro il 5% da F_0 con probabilità almeno 99%.

Supponiamo inoltre che l'universo abbia dimensione $n = |\mathcal{U}|$ e che ogni elemento x_i richieda b bit per essere rappresentato.

Le garanzie di accuratezza devono convivere con vincoli stringenti di tempo e memoria. In questo contesto, un algoritmo di streaming deve:

- processare ciascun elemento con costo $O(1)$ o quasi costante;
- usare memoria molto più piccola di $|\mathcal{U}|$;
- produrre una stima \hat{F}_0 con errore controllato, utilizzando m bit, dove $m \ll n$.

Per rispettare questi vincoli si ricorre a funzioni hash che approssimano una distribuzione uniforme sugli elementi e a strutture compatte, chiamate **sketch**, che riassumono le informazioni essenziali della stream senza conservarla esplicitamente.

Il vincolo più forte è quello di memoria: si richiede che lo spazio cresca molto più lentamente della dimensione dell'universo.

Def. 2.7 (Spazio sublineare). Un algoritmo usa *spazio sublineare* se la memoria m cresce asintoticamente meno di n , cioè $m = o(n)$, dove $n = |\mathcal{U}|$. Si richiede che m dipenda in modo polilogaritmico da n e polinomiale da $1/\varepsilon$ e $\log(1/\delta)$.

ESEMPIO. Per il problema dei distinti esistono algoritmi che ottengono una $(1 \pm \varepsilon)$ -approssimazione usando $O(\varepsilon^{-2} + \log n)$ bit [4], che è molto meno dei $\Omega(n)$ bit necessari per memorizzare l'insieme dei distinti.

2.2 ALGORITMI DI STREAMING

Il modello di data stream, con le caratteristiche appena descritte—flussi potenzialmente infiniti, velocità non controllata e memoria limitata—rende inapplicabili gli approcci classici basati su memorizzazione completa e analisi a posteriori.

Gli algoritmi di streaming nascono per produrre stime e statistiche utili durante l'arrivo dei dati, lavorando in un solo passaggio e mantenendo una sintesi compatta della stream.

Def. 2.8 (Algoritmo di streaming). Un algoritmo di streaming elabora una stream in un solo passaggio e mantiene uno stato interno M di dimensione limitata m . Per ogni elemento x_i della stream, lo stato viene aggiornato tramite una funzione

$$M \leftarrow \text{Update}(M, x_i),$$

e in qualunque momento è possibile ottenere una risposta (o stima) tramite

$$\hat{F}_0 \leftarrow \text{Query}(M).$$

Nel modello classico si richiede che m sia sublineare rispetto a n e che il tempo per aggiornamento sia $O(1)$ o quasi costante [2].

Questa astrazione separa in modo netto il costo di aggiornamento per elemento dalla qualità della stima ottenuta interrogando lo stato compatto.

Dopo ogni aggiornamento, l'elemento appena osservato può essere scartato: lo stato M rappresenta una sintesi compatta dei dati, spesso chiamata *sketch* [5].

La pipeline concettuale del processo di stima è mostrata in Figura 2.1.



Figura 2.1: Pipeline del modello di algoritmi di streaming

Da qui derivano le metriche standard con cui la letteratura confronta gli algoritmi di streaming. In particolare, nel modello classico le prestazioni si misurano in termini di **passaggi** sulla stream, **memoria** usata, **tempo per elemento** e **accuratezza** della risposta. Per algoritmi di approssimazione, l'accuratezza è espressa tramite un rapporto di approssimazione e una probabilità di successo, spesso nel modello (ε, δ) [6].

Per collocare questo modello nel panorama più ampio degli algoritmi che processano input incompleti, è utile confrontarlo con il modello online. Esiste una tipologia di algoritmi, chiamata algoritmi *online* che sono molto simili [7], perché operano senza disporre dell'intero input; tuttavia non sono identici, poiché nel modello streaming è possibile talvolta differire l'azione fino all'arrivo di piccoli blocchi di elementi, pur mantenendo una memoria molto limitata [2, 6]. Un possibile esempio è fornito dagli algoritmi per la *sliding window*, che mantengono riassunti a blocchi per stimare statistiche recenti con memoria limitata [8]. Nel nostro contesto, tutti gli algoritmi implementati e trattati sono anche *online*, perché processano ogni elemento appena arriva, senza differire l'azione.

Nel contesto degli algoritmi di streaming, un tema centrale è il trade-off tra precisione e memoria. Per il problema del calcolo degli elementi distinti, la letteratura evidenzia un legame diretto tra accuratezza e spazio: ridurre ε implica un incremento della memoria necessaria. In particolare, si considerano efficienti gli algoritmi che usano solo spazio polinomiale in $1/\varepsilon$ e logaritmico nella lunghezza della stream e nella dimensione dell'universo, con un costo per elemento molto basso [3]. Questo mette in evidenza il **trade-off** centrale tra precisione e spazio necessario dello sketch.

Questi algoritmi sono spesso randomizzati: la probabilità nella definizione di (ε, δ) è rispetto alle scelte casuali interne dell'algoritmo e rappresenta una garanzia probabilistica sulla qualità della stima [3]. Nelle implementazioni pratiche, questa randomizzazione è tipicamente incarnata dalla funzione di hash, assunta sufficientemente vicina a una scelta casuale (o parametrizzata da un seed). La randomizzazione consente di ridurre drasticamente lo spazio rispetto alle soluzioni deterministiche, a patto di accettare un errore controllato con alta probabilità.

Un'altra differenza rilevante rispetto all'analisi tradizionale è la distinzione tra stime in tempo reale e analisi *offline*. Nei sistemi classici, gli aggiornamenti si registrano in un archivio e le analisi complesse vengono svolte in *warehouse*. Nel modello di streaming, invece, molte applicazioni richiedono elaborazioni sofisticate in quasi tempo reale, come rilevamento di anomalie, monitoraggio di trend o cambiamenti improvvisi, e questo condiziona la progettazione degli algoritmi [2].

È importante notare che in contesti distribuiti è spesso necessario combinare riassunti di porzioni diverse della stream. Il concetto di *mergeabilità* formalizza la possibilità di unire due sintesi in una sintesi della loro unione preservando le garanzie di errore e la dimensione dello stato: questo permette di scalare gli algoritmi a scenari paralleli o gerarchici ed è una proprietà centrale per gli sketch moderni [9]. Nel seguito questa proprietà verrà formalizzata a livello di struttura dati (*sketch*) e di operatore di composizione.

2.3 FUNZIONI DI HASH

Le funzioni hash sono il principale strumento per “randomizzare” lo stream e associare un universo molto grande in un dominio più piccolo, rendendo possibile l’uso di strutture compatte. In molti sketch, la qualità della stima dipende direttamente dalle proprietà della funzione di hash utilizzata [10, 11]. Gli sketch trattati in questa tesi trasformano infatti le chiavi in valori pseudo-casuali e poi estraggono statistiche semplici: per questo motivo, la qualità dell’hash entra direttamente nell’analisi dell’errore.

Def. 2.9 (Funzione di hash). Una funzione di hash h è una funzione deterministica

$$h : \mathcal{U} \rightarrow V,$$

che associa a ogni chiave dell’universo \mathcal{U} un valore in un dominio V di dimensione molto più piccola, tipicamente $V = \{0, 1\}^w$ oppure $V = [0, 1)$ tramite normalizzazione.

Quindi, una funzione di hash mappa dati di lunghezza arbitraria in un valore di lunghezza fissa, chiamato *hash value*, spesso usato per indicizzare delle strutture dati come le tabelle di hash.

Questa trasformazione permette accessi veloci e riduce lo spazio necessario rispetto alla memorizzazione diretta delle chiavi.

Poiché più chiavi possono produrre lo stesso valore, le *collisioni* sono inevitabili: una buona funzione di hash deve essere veloce da calcolare e minimizzare la probabilità di collisione, idealmente distribuendo i valori in modo uniforme sul dominio [12, 10, 11]. In questo senso, uniformità e collisioni descrivono lo stesso fenomeno da due angoli: collisioni sistematiche indicano non-uniformità delle associazioni.

La Figura 2.2 mostra in modo intuitivo la mappatura chiavi→bucket realizzata da una funzione di hash.

Proprietà desiderate. Le proprietà classiche richieste sono: l’**uniformità** (le chiavi sono distribuite in modo uniforme su V), la **bassa probabilità di collisione**, l’**indipendenza** tra le immagini di chiavi diverse e l’**efficienza** di calcolo.

Una funzione di hash con queste proprietà rende la stima degli sketch stabili e con varianza controllata [10, 11].

Def. 2.10 (Modello di hashing uniforme). Nel modello ideale, h è scelta uniformemente a caso dall’insieme di tutte le funzioni $\mathcal{U} \rightarrow V$. In questo caso, per ogni chiave $x \in \mathcal{U}$, il valore $h(x)$ è uniforme in V e le immagini di chiavi distinte sono indipendenti [10, 11].

Def. 2.11 (Famiglia universale [12]). Una famiglia \mathcal{H} di funzioni $\mathcal{U} \rightarrow V$ è *universale* se, per ogni coppia di chiavi distinte $x \neq y$, vale

$$\Pr_{h \leftarrow \mathcal{H}} [h(x) = h(y)] \leq \frac{1}{|V|}.$$




Figura 2.2: Schema di un esempio di tabella di hash

Def. 2.12 (k -wise indipendenza [10]). Una famiglia \mathcal{H} è k -wise indipendente se, per ogni scelta di k chiavi distinte x_1, \dots, x_k , il vettore

$$(h(x_1), \dots, h(x_k))$$

è distribuito uniformemente in V^k quando h è scelta a caso da \mathcal{H} .

Assunzioni tipiche. Nelle analisi teoriche si assume spesso il modello ideale di hashing uniforme; in alternativa si usa una famiglia con un grado limitato di indipendenza (ad esempio k -wise), o una famiglia universale [12, 10]. In pratica, l'uso di funzioni semplici è comune, ma le garanzie possono degradare rispetto al modello ideale se le assunzioni non sono soddisfatte.

Impatto delle scelte. Una funzione di hash non sufficientemente uniforme può introdurre collisioni sistematiche o correlazioni tra registri, con un aumento del bias e della varianza degli stimatori [10, 11].

2.4 SKETCH

Uno *sketch* è una struttura dati probabilistica che riassume una stream attraverso uno stato M aggiornabile con operazioni *update* e interrogabile con operazioni *query*. Lo sketch non conserva gli elementi originali, ma solo le informazioni necessarie per stimare una quantità d'interesse con memoria limitata che deve essere molto inferiore rispetto a conservare i dati originali.

Come accennato prima negli algoritmi di streaming, nei contesti distribuiti, per ottenere un dato globale è necessario poter combinare due sketch costruiti su porzioni diverse della stream. Come possibile esempio, si pensi a due server che creano in maniera indipendente il loro sketch dei dati e che si voglia unire queste informazioni. Intuitivamente, ciò è possibile solo se gli sketch condividono gli stessi parametri strutturali e la stessa funzione di hash (o lo stesso seed), altrimenti la fusione può degradare le garanzie.

Def. 2.13 (Mergeable Sketch). Sia $\mathcal{K}(\cdot)$ la procedura che costruisce uno sketch e sia \oplus un operatore sullo stato. Lo sketch è *mergeable* se, per due stream S_1, S_2 costruite con la stessa parametrizzazione e la stessa funzione di hash,

vale

$$\mathcal{K}(S_1) \oplus \mathcal{K}(S_2) \approx \mathcal{K}(S_1 \cdot S_2),$$

preservando le garanzie di errore (o con degradazione nota) [9].

Nel caso specifico del count-distinct, la concatenazione induce la stessa informazione rilevante dell'unione insiemistica delle chiavi osservate.

Def. 2.14 (Operatore chiuso). Sia \mathcal{S} lo spazio degli stati di uno sketch. Un operatore \oplus è *chiuso* se

$$\oplus : \mathcal{S} \times \mathcal{S} \rightarrow \mathcal{S},$$

ovvero se la combinazione di due stati produce ancora uno stato valido dello stesso tipo.

La Figura 2.3 illustra lo scenario tipico in cui più nodi producono sketch locali che vengono aggregati gerarchicamente.

In pratica, l'operatore \oplus deve essere *chiuso* sullo stato (ad esempio utilizzando la funzione di massimo per registro o la funzione di somma per componente) e, per aggregazioni robuste, è preferibile che sia *commutativo* e *associativo*; in molti casi è utile anche l'*idempotenza* per tollerare duplicazioni.




Figura 2.3: Merge di sketch in un contesto distribuito

Osservazione: Per gli sketch a registri considerati in questa tesi (LogLog, HLL e HLL++), se due sketch hanno stessi parametri e stessa funzione di hash/seed, l'operatore di merge è il massimo componente-per-componente. Con queste condizioni, lo sketch ottenuto dal merge coincide con quello costruito processando la concatenazione delle due stream.

2.5 STIMATORI

In statistica, uno *stimatore* è una funzione dei dati osservati che restituisce una stima di un parametro d'interesse. Nel contesto dello streaming dei dati, la stima dipende sia dalla stream osservata sia dalla randomizzazione interna dell'algoritmo (ad esempio la funzione di hash) [13]. Nel seguito, la stima \hat{F}_0 prodotta da uno sketch viene quindi trattata come variabile aleatoria e descritta con il lessico standard della stima statistica.

Adesso andremo a definire alcuni concetti essenziali affinché sia possibile valutare la qualità di una stima e confrontare diversi algoritmi.

Def. 2.15 (Stimatore). Sia θ un parametro d'interesse e siano X i dati osservati. Uno *stimatore* è una funzione misurabile T tale che

$$\hat{\theta} = T(X),$$

dove $\hat{\theta}$ è una variabile aleatoria [13].

Def. 2.16 (Bias e correttezza). Il *bias* di uno stimatore è

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta.$$

Lo stimatore è *corretto* (unbiased) se il bias è nullo; altrimenti è *biased* [13].

Un bias positivo indica una tendenza sistematica a sovrastimare il valore vero, mentre un bias negativo indica una sottostima. Un bias nullo non garantisce stima precisa in ogni run, ma elimina lo spostamento medio.

Def. 2.17 (Varianza ed errore standard). La *varianza* di uno stimatore è

$$\text{Var}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2],$$

mentre l'*errore standard* è la sua radice quadrata $\text{SE}(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}$ [13].

La varianza descrive quanto le stime oscillano tra esecuzioni: valori piccoli indicano stabilità, valori grandi indicano dispersione. L'errore standard è una misura nella stessa unità di θ e fornisce una scala naturale della variabilità.

Def. 2.18 (Errore di stima e rischio). L'*errore di stima* è la variabile aleatoria

$$E = \hat{\theta} - \theta.$$

Dato una funzione di *loss* $L(E)$, il *rischio* (o rischio atteso) è

$$R(\hat{\theta}) = \mathbb{E}[L(E)].$$

Delle scelte comuni per la funzione di loss sono $L(E) = |E|$ (rischio assoluto) e $L(E) = E^2$ (MSE) [13].

L'errore di stima misura lo scostamento puntuale dalla verità, mentre il rischio riassume l'errore atteso secondo una loss scelta. Loss diverse privilegiano aspetti diversi: l'errore assoluto è più robusto, l'errore quadratico penalizza maggiormente gli scostamenti grandi.

Def. 2.19 (MAE e MSE). Il *Mean Absolute Error* (MAE) è

$$\text{MAE} = \mathbb{E}[|\hat{\theta} - \theta|],$$

mentre il *Mean Squared Error* (MSE) è

$$\text{MSE} = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Il MAE misura l'errore medio assoluto, mentre l'MSE penalizza maggiormente gli errori grandi [13].

Il MAE è facilmente interpretabile come distanza media dalla verità. L'MSE (e la sua radice, l'RMSE) enfatizza gli errori grandi e quindi è sensibile a outlier o code pesanti nelle stime.

Def. 2.20 (Errore relativo). L'*errore relativo* è definito come

$$\text{RE} = \frac{|\hat{\theta} - \theta|}{|\theta|},$$

quando $\theta \neq 0$.

L'errore relativo normalizza lo scarto rispetto alla grandezza del vero valore e rende confrontabili stime su dataset di scala diversa.

Def. 2.21 (Consistenza). Una sequenza di stimatori $\hat{\theta}_n$ è *consistente* se

$$\hat{\theta}_n \xrightarrow{P} \theta \quad \text{quando } n \rightarrow \infty,$$

ossia se la stima converge al valore vero al crescere della quantità di informazione disponibile [13].

Nei capitoli successivi si parlerà anche di **bias correction**, cioè di tecniche che riducono lo spostamento medio della stima tramite calibrazione empirica o aggiustamenti analitici delle formule. Queste tecniche non eliminano necessariamente la varianza, ma migliorano l'accuratezza media.

2.6 METRICHE DI ERRORE

A seguire vengono definite le metriche usate per valutare empiricamente gli stimatori della Sezione 2.5. Vengono fatte R esecuzioni indipendenti, chiamate *run*, con stime $\hat{F}_0^{(r)}$ e valori veri $F_0^{(r)}$.

Per una singola run r vengono calcolati l'errore di stima, il suo valore assoluto e l'errore relativo:

$$e^{(r)} = \hat{F}_0^{(r)} - F_0^{(r)}, \quad |e^{(r)}|, \quad \text{RE}^{(r)} = \frac{|e^{(r)}|}{F_0^{(r)}} \quad (\text{se } F_0^{(r)} > 0).$$

Successivamente, vengono calcolati il bias, la varianza, l'errore standard e per collegarsi alla letteratura sugli sketch, si usa la *Relative Standard Error* (RSE), che normalizza la deviazione standard rispetto alla scala del problema.

Siccome nel nostro framework le run sono eseguite su sottoinsiemi potenzialmente diversi, si introduce la media degli stimatori per il numero di elementi distinti:

$$\bar{F}_0 = \frac{1}{R} \sum_{r=1}^R F_0^{(r)}, \quad \bar{\hat{F}}_0 = \frac{1}{R} \sum_{r=1}^R \hat{F}_0^{(r)}.$$

Nel seguito distinguiamo la varianza teorica $\text{Var}(\hat{F}_0)$ dalla *varianza campionaria* delle run sperimentali:

$$\widehat{\text{Var}}(\hat{F}_0) = \frac{1}{R-1} \sum_{r=1}^R (\hat{F}_0^{(r)} - \bar{\hat{F}}_0)^2, \quad \hat{\sigma} = \sqrt{\widehat{\text{Var}}(\hat{F}_0)}.$$

Come per l'errore, viene stimato il bias, il suo valore assoluto e il suo errore relativo:

$$\widehat{\text{Bias}}(\hat{F}_0) = \bar{\hat{F}}_0 - \bar{F}_0, \quad \text{AB} = |\widehat{\text{Bias}}(\hat{F}_0)|, \quad \text{RB} = \frac{\widehat{\text{Bias}}(\hat{F}_0)}{\bar{F}_0} \quad (\bar{F}_0 \neq 0).$$

L'errore relativo medio empirico (Mean Relative Error, MRE) è

$$\text{MRE} = \frac{1}{R} \sum_{r=1}^R \frac{|\hat{F}_0^{(r)} - F_0^{(r)}|}{F_0^{(r)}},$$

e le metriche aggregate empiriche usate nei risultati includono il Mean Absolute Error (MAE) e il Root Mean Squared Error (RMSE):

$$\text{MAE} = \frac{1}{R} \sum_{r=1}^R |\hat{F}_0^{(r)} - F_0^{(r)}|, \quad \text{RMSE} = \sqrt{\frac{1}{R} \sum_{r=1}^R (\hat{F}_0^{(r)} - F_0^{(r)})^2}.$$

Queste quantità sono stime empiriche dei corrispondenti concetti teorici presentati nella sezione precedente.

La *RSE osservata* è stimata come

$$\text{RSE}_{\text{obs}} = \frac{\hat{\sigma}}{\bar{F}_0}.$$

Questa formula è valida per $\bar{F}_0 > 0$. Se la cardinalità media è nulla, anche la deviazione standard campionaria risulta nulla e la RSE osservata viene posta convenzionalmente a 0. Quando il valore vero è lo stesso in tutte le run ($F_0^{(r)} \equiv F_0$), questa definizione si riduce a $\hat{\sigma}/F_0$. Quando disponibile, si confronta l'RSE osservata con una *RSE teorica* fornita dalla letteratura (ad esempio formule del tipo c/\sqrt{m}), per verificare la coerenza tra predizioni teoriche e risultati sperimentali. Quando invece $F_0^{(r)}$ varia tra run, RSE_{obs} va interpretata come normalizzazione rispetto alla scala media del problema, e non rispetto a un unico valore vero fisso.

2.7 FAMIGLIA DI ALGORITMI PER COUNT-DISTINCT

Il calcolo esatto del numero di distinti F_0 in streaming richiede, nel caso generale, memoria proporzionale al numero di chiavi distinte osservate, poiché occorre mantenere informazione sufficiente a distinguere chiavi già viste da chiavi nuove. Gli algoritmi di sketching rinunciano all'esattezza e producono una stima \hat{F}_0 con garanzie probabilistiche (ε, δ) usando spazio sublineare e update a costo costante [3].

Una linea storica fondamentale per il count-distinct parte dal *Probabilistic Counting* di Flajolet–Martin [14], che usa una funzione di hash per trasformare le chiavi in bitstring pseudo-casuali e ricavare F_0 da statistiche sui pattern di bit. In tutti questi approcci, l'hash rende i bit osservati simili a campioni casuali e la cardinalità viene ricostruita da statistiche di rarità, come pattern rari o sequenze lunghe di zeri. Successivamente, LogLog [15] e HyperLogLog [16] introducono una struttura a m registri (ottenuti partizionando via hash), aggiornata tramite il numero di zeri iniziali: l'aggregazione su più registri riduce la varianza e porta a un errore relativo che decresce tipicamente come $O(1/\sqrt{m})$. HyperLogLog++ [17] mantiene l'impianto a registri ma introduce correzioni e accorgimenti pratici (ad esempio per il small-range) che riducono il bias e migliorano l'accuratezza su diverse scale di cardinalità.

Questi algoritmi condividono inoltre una proprietà operativa importante: essendo lo stato basato su aggiornamenti monotoni per registro, la fusione di sketch costruiti su partizioni disgiunte della stream è naturale (ad esempio tramite massimo componente-per-componente), rendendo tali metodi adatti a scenari distribuiti [16, 9]. Il Capitolo 3 riprende questa linea evolutiva confrontando, per ogni algoritmo, la struttura dello sketch e i meccanismi di correzione dell'errore.

2.8 ALTRI OBIETTIVI DI SKETCHING

Sebbene il focus principale della tesi sia il count-distinct, il framework è pensato per includere anche sketch con obiettivi diversi.

Def. 2.22 (Stima di frequenza puntuale). Dato un elemento $a \in \mathcal{U}$, una query di frequenza restituisce una stima $\hat{f}(a)$ della frequenza reale $f(a)$. Nei metodi approssimati, la garanzia è tipicamente espressa come errore additivo controllato con probabilità alta.

Def. 2.23 (Membership approssimata). Data una chiave x , una query di membership decide se x appartiene all'insieme osservato. Le strutture approssimate sono spesso progettate per non produrre falsi negativi, accettando una probabilità controllata di falsi positivi.

Nel Capitolo 3, oltre alla famiglia $\text{FM} \rightarrow \text{HLL++}$, verranno quindi introdotti anche Count-Min Sketch per frequenze e Bloom filter per membership [18, 19, 20].

2.9 SPAZIO E ACCURATEZZA

Analizzando algoritmi di streaming per il count-distinct, è importante caratterizzare il rapporto tra spazio e accuratezza. Senza entrare nei dettagli di uno specifico algoritmo, esistono limiti teorici generali che guidano la progettazione degli sketch.

Utilizzando il modello probabilistico (ε, δ) per la qualità della stima, esistono degli algoritmi di streaming che producono una $(1 \pm \varepsilon)$ -approssimazione di F_0 con probabilità almeno $1 - \delta$ usando spazio $\tilde{O}(\varepsilon^{-2} \log(1/\delta) + \log n)$ bit, dove $n = |\mathcal{U}|$ e \tilde{O} nasconde fattori polilogaritmici [21, 4].

Inoltre, esistono lower bound dello stesso ordine di grandezza, per cui tale dipendenza è ottimale a livello di ordine [4].

Di conseguenza, ridurre ε di un fattore 2 richiede circa 4 volte la memoria, poiché lo spazio cresce come ε^{-2} .

Mentre, ridurre δ richiede solo un fattore logaritmico, ottenibile tramite ripetizioni indipendenti e combinazione (ad esempio *median trick* [22]).

Questo andamento rende naturale ottimizzare soprattutto la dipendenza da ε , mentre δ viene spesso gestito tramite amplificazione della probabilità di successo.

Nel caso di HyperLogLog, la deviazione standard relativa (RSE) scala come $\Theta(1/\sqrt{m})$, dove m è il numero di registri; in altre parole, raddoppiare m riduce l'errore di un fattore circa $\sqrt{2}$ [16]. Nei capitoli sperimentali questa relazione verrà verificata empiricamente variando m e osservando l'andamento di RSE.

3

Un'analisi sullo stato dell'arte

Nel capitolo 2 abbiamo definito le nozioni necessarie collegate agli *algoritmi di streaming*, in questo capitolo analizzeremo lo *stato dell'arte* degli algoritmi per la stima di F_0 (il numero di elementi distinti). L'obiettivo è definire l'attuale stato dell'arte e chiarire quali scelte algoritmiche portano ai migliori compromessi tra memoria, accuratezza e componibilità distribuita.

3.1 OBIETTIVO DEL PROBLEMA E VINCOLI TEORICI

Il problema del *count-distinct* consiste nello stimare

$$F_0 = |\{a \in \mathcal{U} : f(a) > 0\}|,$$

ossia la cardinalità del supporto del vettore delle frequenze. Nel quadro dei *frequency moments*, F_0 rappresenta il primo problema canonico di stima con memoria sublineare in streaming [21, 3].

In un modello *insertion-only*, un algoritmo deve processare ogni elemento in uno o pochi passaggi, con tempo di aggiornamento molto basso e stato ridotto. In generale, il calcolo esatto richiede memoria lineare nel numero di distinti osservati, di conseguenza non può scalare all'aumentare degli elementi visti. In un contesto in cui la stream può crescere senza un limite prefissato, questa soluzione non è praticabile. Per questo motivo si ricorre a sketch randomizzati con garanzie probabilistiche (ε, δ) , già formalizzate nel Capitolo 2.

Dal lato teorico, esistono algoritmi ottimali per il problema dei distinti che raggiungono spazio dell'ordine $O((\varepsilon^{-2} + \log n) \text{polylog } n)$, mostrando che la dipendenza da ε^{-2} è strutturale e non un artefatto implementativo [4]. Questa cornice giustifica l'uso di famiglie algoritmiche in cui l'accuratezza cresce come $\Theta(1/\sqrt{m})$, dove m è la memoria effettiva dello sketch.

In [4] viene mostrato come i migliori risultati generali riportati prima dell'algoritmo ottimale avevano spazio $O(\varepsilon^{-2}(\log(1/\varepsilon) + \log \log n) + \log n)$ e tempo di update $O(\varepsilon^{-2}(\log(1/\varepsilon) + \log \log n))$, mentre il risultato ottimale raggiunge spazio $O(\varepsilon^{-2} + \log n)$ bit e update/query in $O(1)$.

3.2 SVILUPPO STORICO

La progressione storica degli algoritmi di cardinalità può essere vista come una sequenza di miglioramenti sulla stessa idea centrale: usare una funzione di hash per trasformare la stream di dati in valori pseudo-casuali e comprimere l'informazione in un unico stato di dimensioni molto ridotte.

3.2.1 PROBABILISTIC COUNTING

Il lavoro in [14] introduce il paradigma del conteggio probabilistico: da ogni chiave si ricava un valore di hash e si osserva la posizione del primo bit significativo (oppure il numero di zeri iniziali). Gli eventi rari, come molti zeri iniziali, diventano indicatori della scala di grandezza di F_0 .

La formulazione di base mantiene una bitmap e marca posizioni osservate; la successiva variante, chiamata *Probabilistic Counting with Stochastic Averaging* (**PCSA**), partiziona la stream in più sottostream indipendenti tramite hash, riducendo la varianza rispetto a una singola statistica globale.

Def. 3.1 (PCSA). Sia $h : \mathcal{U} \rightarrow \{0, 1\}^L$ una funzione di hash uniforme, con $L = w$ (lunghezza in bit del valore di hash). Indicando con $\rho(y)$ la posizione del primo bit a 1 in y , vale:

$$\rho(y) = \min\{r \geq 1 : y_r = 1\},$$

e, sotto l'ipotesi di uniformità, la variabile $\rho(y)$ ha coda geometrica:

$$\Pr[\rho(y) \geq t] = 2^{-(t-1)}.$$

Questa proprietà è la base della stima di cardinalità: osservare valori grandi di ρ diventa più probabile quando cresce il numero di distinti. Nel caso di PCSA, la partizione in m sottostream rende più stabile la stima rispetto alla versione PC con una sola statistica globale [14].

In pratica, PCSA non crea m stream fisiche separate: la partizione è *virtuale* ed è indotta dalla funzione di hash. Ogni elemento x viene assegnato a un indice $j \in \{0, \dots, m-1\}$; gli elementi con lo stesso indice aggiornano la stessa bitmap $B[j]$. In questo modo, la stima finale combina informazione proveniente da più sottogruppi indipendenti (in media), riducendo la variabilità rispetto al caso con una sola bitmap.

Per l'esempio seguente assumiamo bitmap di lunghezza 4 e rappresentiamo ogni bitmap come $[b_1 b_2 b_3 b_4]$, dove $b_r = 1$ indica che la posizione r è stata osservata almeno una volta.

Nell'esempio della Tabella 3.1, gli elementi a e c finiscono nello stesso sottostream ($j = 1$), mentre b e d vengono indirizzati a sottostream diversi. Ogni riga aggiorna quindi una sola bitmap $B[j]$ e la stima finale media i contributi delle bitmap. In particolare, nello stato finale risultano attive tre bitmap su quattro, con stima finale $\hat{F}_0 \approx 14.62$ (in questo esempio volutamente piccolo).

Passo	x	$y = h(x)$	$j = y \bmod 4$	$t = \lfloor y/4 \rfloor$	$r = \rho(t)$	Update	Stato bitmap ($B_0 B_1 B_2 B_3$)	\hat{F}_0 (PCSA)
1	a	25	1	6 (110_2)	2	$B[1, 2] \leftarrow 1$	0000 0100 0000 0000	≈ 10.34
2	b	14	2	3 (11_2)	1	$B[2, 1] \leftarrow 1$	0000 0100 1000 0000	≈ 12.29
3	c	9	1	2 (10_2)	2	$B[1, 2] \leftarrow 1$	0000 0100 1000 0000	≈ 12.29
4	d	7	3	1 (1_2)	1	$B[3, 1] \leftarrow 1$	0000 0100 1000 1000	≈ 14.62

Tabella 3.1: Esempio minimale di partizione PCSA in $m = 4$ sottostream virtuali.

Algoritmo 3.1 PCSA (adapted from Fig. 1 in [14])

Choose m bitmaps $B[0], \dots, B[m-1]$ of length L , initialize all bits to 0

Choose a hash function $h : \mathcal{U} \rightarrow \{0, 1\}^L$ with L large enough

for each element x in the stream

$y \leftarrow h(x)$

$j \leftarrow y \bmod m$

$t \leftarrow \lfloor y/m \rfloor$

$r \leftarrow \rho(t)$

Set $B[j, r] \leftarrow 1$

end for

for $j = 0$ **to** $m - 1$

$R_j \leftarrow \text{FIRSTZERO}(B[j])$

end for

$\bar{R} \leftarrow \frac{1}{m} \sum_{j=0}^{m-1} R_j$

$\hat{F}_0 \leftarrow \frac{m}{\phi} \cdot 2^{\bar{R}}$ with $\phi \approx 0.77351$

return \hat{F}_0

Nel paper [14] vengono anche discussi bias, errore standard e modalità di uso pratico (numero di bitmap, correzioni per piccoli range, parallelizzazione)

Nella forma PCSA, ai fini di trovare il valore corretto per la costante ϕ esso è stato calcolato empiricamente e l'errore relativo standard atteso è circa $0.78/\sqrt{m}$. Gli autori riportano anche ordini di grandezza pratici: con $m = 64$ si ottiene tipicamente un errore intorno al 10%, mentre con $m = 256$ si scende intorno al 5%.

COMPLESSITÀ Con m bitmap di lunghezza L , lo spazio è

$$S_{\text{PCSA}}(m, L) = \Theta(mL) \text{ bit.}$$

L'update richiede tempo $\Theta(1)$ per elemento. La query richiede $\Theta(mL)$ nel caso diretto (scansione per trovare il primo zero di ogni bitmap) oppure $\Theta(m)$ se si mantiene informazione ausiliaria sul primo zero per ciascuna bitmap.

3.2.2 LOGLOG

LogLog sostituisce la bitmap con un array di registri e applica *stochastic averaging* in modo più efficiente: il prefisso dell'hash seleziona il registro, mentre il suffisso determina il valore ρ da propagare come massimo. La stima finale usa una media geometrica normalizzata [15].

Def. 3.2 (LogLog). Sia $m = 2^p$ il numero di registri. Per ogni elemento x si calcola $y = h(x)$, si usa il prefisso di p bit per selezionare il registro j , e il suffisso per calcolare $\rho(w)$. L'update è quindi:

$$M[j] \leftarrow \max\{M[j], \rho(w)\}.$$

Indicando con

$$A = \frac{1}{m} \sum_{j=0}^{m-1} M[j],$$

lo stimatore LogLog ha forma

$$\hat{F}_0 = \alpha_m \cdot m \cdot 2^A,$$

dove α_m è una costante di calibrazione (asintoticamente circa 0.397). L'errore relativo standard tipico è dell'ordine $\approx 1.30/\sqrt{m}$ [15].

La relazione con F_0 può essere letta anche in modo esplicito: il numero atteso di elementi che cadono in ciascun registro è circa F_0/m , quindi i massimi $M[j]$ tendono a concentrarsi attorno a $\log_2(F_0/m)$; la media dei registri fornisce quindi una stima logaritmica della cardinalità complessiva.

Il passaggio chiave rispetto a PC è che, a parità di memoria, la dispersione della stima si riduce sensibilmente grazie all'aggregazione su molti registri.

ESEMPIO. Consideriamo un caso minimale con $p = 2$ ($m = 4$ registri) e hash su 8 bit. I primi 2 bit selezionano il registro j , i restanti 6 bit formano il suffisso w su cui si calcola $\rho(w)$.

Algoritmo 3.2 LogLog (adapted from [15])

```

Choose precision  $p$  and set  $m = 2^p$ 
Initialize registers  $M[0], \dots, M[m-1] \leftarrow 0$ 
for each element  $x$  in the stream
     $y \leftarrow h(x)$ 
     $j \leftarrow \text{PREFIX}_p(y)$ 
     $w \leftarrow \text{SUFFIX}_{L-p}(y)$ 
     $M[j] \leftarrow \max\{M[j], \rho(w)\}$ 
end for
 $A \leftarrow \frac{1}{m} \sum_{j=0}^{m-1} M[j]$ 
 $\hat{F}_0 \leftarrow \alpha_m \cdot m \cdot 2^A$ 
return  $\hat{F}_0$ 

```

Passo	x	$y = h(x)$	$j = \text{PREFIX}_2(y)$	$w = \text{SUFFIX}_6(y)$	$\rho(w)$	Update	Stato registri (M_0, M_1, M_2, M_3)	\hat{F}_0 (LogLog)
1	a	10010100 ₂	2	010100 ₂	2	$M[2] \leftarrow \max(0, 2) = 2$	(0, 0, 2, 0)	≈ 2.25
2	b	10111000 ₂	2	111000 ₂	1	$M[2] \leftarrow \max(2, 1) = 2$	(0, 0, 2, 0)	≈ 2.25
3	c	01001100 ₂	1	001100 ₂	3	$M[1] \leftarrow \max(0, 3) = 3$	(0, 3, 2, 0)	≈ 3.78
4	d	11001000 ₂	3	001000 ₂	3	$M[3] \leftarrow \max(0, 3) = 3$	(0, 3, 2, 3)	≈ 6.35
5	e	10000100 ₂	2	000100 ₂	4	$M[2] \leftarrow \max(2, 4) = 4$	(0, 3, 4, 3)	≈ 8.99

Tabella 3.2: Esempio operativo di LogLog con aggiornamento dei registri.

Nella Tabella 3.2 si vede la logica centrale di LogLog: ogni elemento aggiorna un solo registro e l'operazione è sempre un massimo, quindi i registri crescono monotonicamente. La colonna \hat{F}_0 mostra la stima LogLog ottenuta dopo ogni passo, usando la formula del paragrafo con $\alpha_m \approx 0.397$.

COMPLESSITÀ Se ogni registro codifica valori in $[0, L - p + 1]$, servono $\lceil \log_2(L - p + 2) \rceil$ bit per registro. Quindi

$$S_{\text{LogLog}}(m, L, p) = \Theta(m \log(L - p + 2)) \text{ bit.}$$

L'update è $\Theta(1)$ per elemento e la query è $\Theta(m)$.

LIMITI PRATICI. LogLog riduce nettamente la varianza rispetto a FM, ma resta sensibile alla costante di normalizzazione e alla qualità dell'hash. In particolare, quando la cardinalità è molto piccola rispetto a m , la stima tende ad avere bias maggiore rispetto alle varianti successive.

3.2.3 HYPERLOGLOG

HyperLogLog (HLL) mantiene la stessa struttura a registri di LogLog ma cambia la funzione di stima: usa una media armonica delle quantità $2^{-M[j]}$, ottiene una migliore analizzabilità e una costante di errore più favorevole. Il risultato classico è una deviazione standard relativa tipica $\text{RSE} \approx 1.04/\sqrt{m}$ [16].

Def. 3.3 (HyperLogLog). Definendo

$$Z = \sum_{j=0}^{m-1} 2^{-M[j]},$$

la stima grezza di HLL è:

$$E = \alpha_m \frac{m^2}{Z},$$

con costanti pratiche

$$\alpha_{16} = 0.673, \quad \alpha_{32} = 0.697, \quad \alpha_{64} = 0.709,$$

e per $m \geq 128$:

$$\alpha_m \approx \frac{0.7213}{1 + 1.079/m}.$$

La scelta della media armonica non è solo formale: attenua il peso dei registri con valori estremi e produce una stima più stabile rispetto a LogLog. Dal punto di vista statistico, la varianza scende mantenendo la stessa struttura di update, con un vantaggio diretto nel rapporto memoria/accuratezza.

Nella variante pratica del paper, si applicano correzioni di range. Se V_0 è il numero di registri a zero:

$$\hat{F}_0 = \begin{cases} m \log(m/V_0), & \text{se } E \leq \frac{5}{2}m \text{ e } V_0 > 0 \\ E, & \text{nel regime centrale} \\ -2^{32} \log\left(1 - \frac{E}{2^{32}}\right), & \text{nel regime vicino a } 2^{32}. \end{cases}$$

L'articolo [16] fornisce sia l'analisi asintotica, sia la variante pratica con correzioni di range, che costituisce il riferimento per implementazioni sperimentali riproducibili.

ESEMPIO. Se $m = 1024$ e dopo gli update molti registri restano nulli (V_0 grande), la stima $m \log(m/V_0)$ risulta più affidabile della stima grezza E . Quando la cardinalità cresce e i registri nulli diminuiscono, la stima entra nel regime centrale basato sulla media armonica.

COMPLESSITÀ Con $m = 2^p$ registri, lo spazio è

$$S_{\text{HLL}}(m, L, p) = \Theta(m \log(L - p + 2)) \text{ bit},$$

che in pratica viene spesso implementato con registri di ampiezza fissa (tipicamente 5–6 bit). Il tempo di update è $\Theta(1)$ per elemento e la query è $\Theta(m)$.

Le formule precedenti assumono parametrizzazione coerente dello sketch ($m = 2^p$), stessa definizione di ρ , e funzione di hash sufficientemente uniforme. In presenza di hash distorto, i registri non campionano più correttamente la stream e la stima può mostrare bias non trascurabile.

Nel paper originale, la procedura è esplicitamente separata in due parti: *raw estimator* e *range correction*. Questa separazione è importante perché il comportamento asintotico (regime centrale) e quello ai bordi (cardinalità molto piccole o vicine al dominio hash) sono governati da meccanismi diversi [16].

Algoritmo 3.3 HyperLogLog (adapted from Fig. 3 in [16])

Choose precision p , set $m = 2^p$, initialize $M[0..m-1] \leftarrow 0$

for each element x in the stream

$y \leftarrow h(x)$

$j \leftarrow \text{PREFIX}_p(y)$

$w \leftarrow \text{SUFFIX}_{L-p}(y)$

$M[j] \leftarrow \max\{M[j], \rho(w)\}$

end for

$Z \leftarrow \sum_{j=0}^{m-1} 2^{-M[j]}$

$E \leftarrow \alpha_m m^2 / Z$ (raw estimate)

if $E \leq \frac{5}{2}m$

$V_0 \leftarrow$ number of registers equal to 0

if $V_0 \neq 0$

$E^* \leftarrow m \log(m/V_0)$

else

$E^* \leftarrow E$

end if

else if $E \leq \frac{1}{30} \cdot 2^{32}$

$E^* \leftarrow E$

else

$E^* \leftarrow -2^{32} \log(1 - E/2^{32})$

end if

return $\hat{F}_0 \leftarrow E^*$

3.2.4 HYPERLOGLOG++

HLL++ nasce come evoluzione pratica di HLL in scenari industriali ad alta scala. I miglioramenti principali sono:

- uso di una hash a 64 bit per ritardare gli effetti di saturazione;
- rappresentazione *sparse* per cardinalità piccole;
- bias correction empirica tramite tabelle/interpolazione;
- scelta adattiva tra linear counting e stima HLL corretta.

Def. 3.4 (HyperLogLog++). La struttura mantiene la stessa regola di update di HLL sui registri, ma introduce due passaggi aggiuntivi: rappresentazione sparsa nelle cardinalità piccole e correzione empirica del bias. Indicando con E la stima HLL grezza, la stima corretta è:

$$E_{\text{corr}} = E - \text{bias}(E, p),$$

dove il termine di bias è tabulato per ciascun livello di precisione p (interpolazione tra punti noti). La stima finale sceglie il ramo con errore atteso minore tra linear counting ed E_{corr} [17].

Nel formato *sparse*, lo sketch memorizza solo i registri non nulli (coppie indice-valore), riducendo spazio e costo costante nelle cardinalità piccole. Il passaggio a formato *dense* avviene quando la rappresentazione sparsa non è più conveniente in memoria.

La formulazione in [17] usa due precisioni: p per lo sketch *dense* e p' (con $p \leq p' \leq 64$) per la codifica *sparse*; in questo modo lo stesso algoritmo può avere uno spazio molto più piccolo quando la cardinalità è bassa, senza perdere compatibilità con la stima HLL nel regime normale [17].

Le routine ausiliarie usate nel pseudocodice hanno significato preciso: $\text{LINEARCOUNTING}(m, V_0) = m \log(m/V_0)$ per $V_0 > 0$, $\text{ESTIMATEBIAS}(E, p)$ applica l'interpolazione sulla tabella empirica del bias (nel paper con schema di nearest neighbours), e $\text{THRESHOLD}(p)$ è la soglia empirica di switch tra i due rami di stima riportata in Figura 6 [17]. Nel ramo *sparse* la stessa formula di linear counting viene applicata con $m' = 2^{p'}$ e con il numero di registri non nulli dedotto dalla sparse list.

Nel lavoro del 2013, il contributo non è una nuova famiglia teorica separata, bensì una rifinitura sistematica di HLL per ridurre il bias pratico e migliorare l'accuratezza nelle cardinalità piccole e intermedie [17].

Il paper specifica che $\text{THRESHOLD}(p)$ è determinata empiricamente (tabulata per ogni precisione) e che le routine ausiliarie $\text{MERGE}/\text{TONORMAL}$ sono parte essenziale della transizione sparse to dense. Nella discussione implementativa, gli autori descrivono anche una strategia pratica in cui il *temporary set* viene fuso periodicamente (ad esempio intorno al 25% della capacità massima della rappresentazione sparsa) per mantenere efficiente la gestione degli inserimenti [17].

ESEMPIO. Con $p = 14$ ($m = 16384$), per cardinalità piccole lo sketch può restare in formato sparse, riducendo la memoria effettiva. Superata una soglia, la struttura passa in dense e usa l'estimatore HLL corretto dal bias.

Algoritmo 3.4 HyperLogLog++ (adapted from Fig. 6 in [17])

Input: stream S , precisions p and p' with $p \leq p' \leq 64$
 $m \leftarrow 2^p, \quad m' \leftarrow 2^{p'}$
 $\alpha_{16} \leftarrow 0.673, \alpha_{32} \leftarrow 0.697, \alpha_{64} \leftarrow 0.709$
 $\alpha_m \leftarrow 0.7213/(1 + 1.079/m)$ for $m \geq 128$
Initialize sparse mode, temporary set, sparse list, and dense registers
for each element x in S
 $y \leftarrow h_{64}(x)$
 Encode sparse value from y using (p, p')
 if mode is sparse
 Insert encoded value in temporary set
 if temporary set is full ($|\text{temporary_set}| \geq 0.25 \cdot 2^{p'}$)
 Merge temporary set into sparse list
 end if
 if $|\text{sparse_list}| > 6m$ bits
 Convert sparse representation to dense registers
 mode \leftarrow normal
 end if
 else
 Extract (j, ρ) from y
 $M[j] \leftarrow \max\{M[j], \rho\}$
 end if
end for
if mode is sparse
 Merge temporary set into sparse list
 return LINEARCOUNTING($m', m' - |\text{sparse_list}|$)
else
 $E \leftarrow \alpha_m m^2 \left(\sum_{j=0}^{m-1} 2^{-M[j]} \right)^{-1}$
 if $E \leq 5m$
 $E' \leftarrow E - \text{ESTIMATEBIAS}(E, p)$
 else
 $E' \leftarrow E$
 end if
 $V_0 \leftarrow$ number of registers equal to 0
 if $V_0 \neq 0$
 $H \leftarrow \text{LINEARCOUNTING}(m, V_0)$
 else
 $H \leftarrow E'$
 end if
 if $H \leq \text{THRESHOLD}(p)$
 return H
 else
 return E'
 end if
end if

COMPLESSITÀ In modalità *sparse*, lo spazio è $\Theta(|\text{sparse_list}|)$ (in bit codificati) fino alla soglia di conversione; in modalità *dense*, lo spazio è $\Theta(m)$ registri (spesso circa $6m$ bit in implementazioni pratiche). L'update è $\Theta(1)$ ammortizzato, con costo $\Theta(m)$ durante la conversione sparse to dense. La query è $\Theta(|\text{sparse_list}|)$ in sparse e $\Theta(m)$ in dense.

LIMITI E COMPROMESSI. HLL++ riduce bias pratico, soprattutto nei range piccoli e intermedi, ma introduce maggiore complessità ingegneristica: soglie di switching, tabelle di correzione e doppia rappresentazione dello stato. Per questo motivo è importante distinguere sempre tra specifica teorica dell'estimatore e dettagli implementativi della variante “in practice”.

3.3 CONFRONTO SINTETICO TRA GLI APPROCCI

La Tabella 3.3 riassume le differenze principali tra gli algoritmi della linea storica.

Dal punto di vista formale, la differenza principale non è l'ordine asintotico ($\Theta(1/\sqrt{m})$ domina asintoticamente), ma la costante moltiplicativa dell'errore, il comportamento ai bordi di range e la robustezza in scenari reali dove hash, cardinalità e distribuzioni non sono ideali.

Algoritmo	Stato dello sketch	Regola di stima	Space	Ordine errore
PCSA	Bitmap (una o più)	Primo zero / media su bitmap	$O(\varepsilon^{-2} \log n)$	$\Theta(1/\sqrt{m})$
LogLog	Array registri (max di ρ)	Media geometrica normalizzata	$O(\varepsilon^{-2} \log \log n + \log n)$	$\Theta(1/\sqrt{m})$
HLL	Array registri (max di ρ)	Media armonica + range corrections	$O(\varepsilon^{-2} \log \log n + \log n)$	$\approx 1.04/\sqrt{m}$
HLL++	Registri + formato sparse	HLL + bias correction + adaptive switching	$O(\varepsilon^{-2} \log \log n + \log n)$	$\Theta(1/\sqrt{m})$ con minore bias pratico

Tabella 3.3: Confronto ad alto livello tra i principali algoritmi count-distinct.

La colonna “Space” è uniformata in notazione teorica rispetto a n ed ε . In questa forma, LogLog/HLL/HLL++ hanno lo stesso ordine $O(\varepsilon^{-2} \log \log n + \log n)$; HLL++ migliora soprattutto costanti e regimi pratici (bias e small-range), non l'ordine asintotico dominante. Nella colonna “Ordine errore” si riporta invece l'andamento della RSE rispetto al numero di registri m (non alla memoria totale in bit): l'ordine asintotico resta $\Theta(1/\sqrt{m})$, ma con costanti diverse (ad esempio 1.04 per HLL) e con correzioni pratiche aggiuntive nel caso HLL++.

La traiettoria evolutiva è quindi chiara: dalla robustezza concettuale di FM si passa a strutture a registri sempre più stabili, fino a HLL/HLL++, che rappresentano oggi il punto di riferimento pratico per il rapporto spazio-accuratezza.

La tabella precedente evidenzia anche che, a parità di ordine asintotico dominante, le differenze pratiche dipendono molto dalla gestione dei regimi di cardinalità e della correzione del bias.

3.4 CORREZIONI DI RANGE E RIDUZIONE DEL BIAS

Nel confronto tra algoritmi non basta riportare una formula di stima grezza; conta anche la gestione dei regimi in cui la formula asintotica non è ancora stabile.

Per HLL, il riferimento classico distingue almeno tre zone [16]:

- **small-range**: uso di *linear counting* quando molti registri restano a zero;
- **raw-range**: uso dell'estimatore armonico principale;
- **large-range**: correzione per la vicinanza al limite del dominio hash.

HLL++ mantiene questa logica ma aggiunge una correzione empirica del bias e una gestione sparse/dense che riduce l'errore nei range in cui HLL classico tende a sovrastimare [17].

In generale, il principio metodologico è che il comportamento empirico deve essere confrontato con la teoria: quando la letteratura fornisce una RSE theoretical (ad esempio $1.04/\sqrt{m}$), le misure sperimentali vanno lette in quella cornice e non isolate.

3.5 MERGEABILITÀ E SCENARI DISTRIBUITI

Una proprietà fondamentale degli sketch di cardinalità moderni è la *mergeability*: la possibilità di costruire sketch locali su partizioni della stream e combinarli in uno sketch globale senza dover rivedere i dati originali [9].

Per LogLog, HLL e HLL++, mantenendo la notazione del Capitolo 2, la regola di merge naturale è:

$$(\mathcal{K}(S_1) \oplus \mathcal{K}(S_2))[j] = \max\{\mathcal{K}(S_1)[j], \mathcal{K}(S_2)[j]\}.$$

Per ogni registro j , lo stato dello sketch di una stream S contiene:

$$\mathcal{K}(S)[j] = \max_{x \in S: j(x)=j} \rho(w(x)).$$

Qui $j(x)$ è la funzione che mappa l'elemento x nel registro selezionato dai primi $\log_2 m$ bit dell'hash, mentre $w(x)$ è il suffisso su cui si valuta ρ , in linea con le sezioni precedenti su LogLog e HLL. Se i due sketch sono costruiti con stessa parametrizzazione e stessa funzione di hash/seed, allora per ogni j :

$$\mathcal{K}(S_1 \cdot S_2)[j] = \max(\mathcal{K}(S_1)[j], \mathcal{K}(S_2)[j]).$$

Quindi il merge registro per registro coincide con lo stato che si otterrebbe processando la concatenazione delle due stream:

$$\mathcal{K}(S_1) \oplus \mathcal{K}(S_2) = \mathcal{K}(S_1 \cdot S_2).$$

Questa operazione è commutativa, associativa e idempotente, quindi è adatta a pipeline distribuite (albero, catena, map-reduce). Inoltre, a parità di parametri e funzione hash/seed, il risultato del merge è equivalente allo stato che si otterrebbe processando sequenzialmente l'unione delle stream.

Per PC/PCSA, la mergeabilità dipende dalla codifica dello stato: in forma bitmap la combinazione è una OR componente-per-componente, mentre in forme basate su massimi si usa ancora il massimo per componente [14].

3.6 ESTENSIONI OLTRE IL COUNT-DISTINCT

Oltre alla stima di F_0 , il framework può trattare sketch con obiettivi diversi: stima di frequenze e query di membership. Riprendendo la notazione (ε, δ) e i simboli di memoria già introdotti nei capitoli precedenti, queste strutture mantengono la stessa impostazione metodologica: stato compatto, garanzie probabilistiche e trade-off esplicito tra precisione e spazio. Nel caso frequenze, ε controlla un errore additivo $\varepsilon \|f\|_1$ con probabilità $1 - \delta$; nel caso membership (Bloom filter), il trade-off è espresso soprattutto dalla probabilità di falso positivo p_{fp} , determinata da m_{bf} e k_{bf} .

3.6.1 COUNT-MIN SKETCH

Def. 3.5 (Count-Min Sketch). Il Count-Min Sketch mantiene una matrice di contatori $C \in \mathbb{N}^{d \times w_{cm}}$ e d funzioni di hash $h_1, \dots, h_d : \mathcal{U} \rightarrow [w_{cm}]$. Per ogni update dell'elemento x , si incrementa $C[j, h_j(x)]$ per ogni riga j ; la stima puntuale è

$$\hat{f}(x) = \min_{j \in [d]} C[j, h_j(x)].$$

Per $w_{cm} = \lceil e/\varepsilon \rceil$ e $d = \lceil \ln(1/\delta) \rceil$, vale con probabilità almeno $1 - \delta$:

$$f(x) \leq \hat{f}(x) \leq f(x) + \varepsilon \|f\|_1.$$

dove $\|f\|_1$ è la somma delle frequenze (lunghezza della stream). [18]

ESEMPIO. Consideriamo un CMS con $d = 2$ righe e $w_{cm} = 5$ colonne (indici $0, \dots, 4$), inizialmente tutto a zero. Supponiamo: $h_1(a) = 1, h_2(a) = 3, h_1(b) = 4, h_2(b) = 1, h_1(c) = 1, h_2(c) = 4$. Processiamo la stream a, b, a, c, a .

Passo	x	$(h_1(x), h_2(x))$	Update	Stato riga 1	Stato riga 2
1	a	(1, 3)	$C[1, 1] ++, C[2, 3] ++$	[0, 1, 0, 0, 0]	[0, 0, 0, 1, 0]
2	b	(4, 1)	$C[1, 4] ++, C[2, 1] ++$	[0, 1, 0, 0, 1]	[0, 1, 0, 1, 0]
3	a	(1, 3)	$C[1, 1] ++, C[2, 3] ++$	[0, 2, 0, 0, 1]	[0, 1, 0, 2, 0]
4	c	(1, 4)	$C[1, 1] ++, C[2, 4] ++$	[0, 3, 0, 0, 1]	[0, 1, 0, 2, 1]
5	a	(1, 3)	$C[1, 1] ++, C[2, 3] ++$	[0, 4, 0, 0, 1]	[0, 1, 0, 3, 1]

Tabella 3.4: Esempio operativo di Count-Min Sketch.

Dallo stato finale della Tabella 3.4, per a si ottiene $\hat{f}(a) = \min\{C[1, 1], C[2, 3]\} = \min\{4, 3\} = 3$ (valore esatto), mentre la struttura resta in generale sovrastimante in presenza di collisioni.

COMPLESSITÀ Lo spazio è $\Theta(d w_{\text{cm}})$ contatori, quindi $\Theta(d w_{\text{cm}} \log \|f\|_1)$ bit con contatori interi standard. Update e query puntuale costano $\Theta(d) = \Theta(\log(1/\delta))$. La mergeabilità è per somma componente-per-componente di matrici compatibili.

3.6.2 BLOOM FILTER (MEMBERSHIP)

Def. 3.6 (Bloom Filter). Un Bloom filter è un array di m_{bf} bit con k_{bf} hash. L’inserimento di x imposta a 1 le celle $B[h_1(x)], \dots, B[h_{k_{\text{bf}}}(x)]$; la query di membership risponde “presente” se tutte queste celle valgono 1. La struttura non produce falsi negativi, ma può produrre falsi positivi con probabilità approssimativa

$$p_{\text{fp}} \approx \left(1 - e^{-k_{\text{bf}} n_{\text{ins}} / m_{\text{bf}}}\right)^{k_{\text{bf}}},$$

con n_{ins} numero di elementi inseriti nel filtro. [19, 20]

ESEMPIO. Consideriamo un Bloom filter con $m_{\text{bf}} = 10$ bit (indici $0, \dots, 9$) e $k_{\text{bf}} = 2$ hash. Supponiamo: $h_1(a) = 1, h_2(a) = 6, h_1(b) = 4, h_2(b) = 6, h_1(c) = 1, h_2(c) = 8$.

Passo	Operazione	(h_1, h_2)	Celle toccate	Stato bitset $[b_0 \dots b_9]$	Esito
1	insert(a)	(1, 6)	$b_1, b_6 \leftarrow 1$	[0100001000]	–
2	insert(b)	(4, 6)	$b_4, b_6 \leftarrow 1$	[0100101000]	–
3	insert(c)	(1, 8)	$b_1, b_8 \leftarrow 1$	[0100101010]	–
4	query(z)	(1, 4)	verifica b_1, b_4	[0100101010]	“presente” (falso positivo)
5	query(q)	(2, 9)	verifica b_2, b_9	[0100101010]	“assente”

Tabella 3.5: Esempio operativo di Bloom filter con un falso positivo.

La Tabella 3.5 mostra il comportamento tipico: nessun falso negativo sugli elementi inseriti, ma possibile falso positivo su query di elementi non inseriti.

COMPLESSITÀ Lo spazio è esattamente m_{bf} bit. Update e query costano $\Theta(k_{\text{bf}})$. La mergeabilità, a parità di parametri e hash, è la OR bit-a-bit.

4

Implementazione

Viene descritta l'implementazione del sistema sperimentale per la valutazione di algoritmi per la stima di elementi distinti su una stream. L'architettura è composta da tre moduli principali:

- la logica algoritmica;
- l'I/O del dataset;
- la valutazione, le metriche e l'export CSV.

Il nucleo dell'architettura è implementato in C++ (CLI, framework e sketch), mentre in Python vengono generati i dataset e l'orchestrazione batch dei vari script ed eseguibili.

4.1 ARCHITETTURA DEL SISTEMA

I componenti principali e le rispettive responsabilità sono:

- `main.cpp` e `BenchmarkCli.cpp`: entry point e loop dei comandi possibili (`set`, `show`, `list`, `run`, `runstream`, `runmerge`, `quit`);
- `CliConfig.cpp`: parsing dei comandi, gestione di `RunConfig`, caricamento del contesto a runtime dal dataset (`sampleSize`, `runs`, `seed`);
- `AlgorithmExecutor.cpp`: dispatch sugli algoritmi richiesti e gestione delle tre modalità `RunMode::Normal`, `RunMode::Streaming`, `RunMode::Merge`;
- `BinaryDatasetIO.h`: indicizzazione dei metadati binari, validazione della tabella delle partizioni e dei loader per i valori e i relativi bitset di verità;
- `EvaluationFramework.h`, `EvaluationFramework.tpp` e `CsvResultWriter.h`: gestiscono il protocollo di valutazione e serializzazione dei risultati;

- All'interno di `src/satp/algorithms/*.cpp` sono presenti le implementazioni concrete degli sketch (HyperLogLog++, HyperLogLog, LogLog, ProbabilisticCounting, TODO: CountMin e Bloom Filter);
- `generate_partitioned_dataset_bin.py`: generazione deterministica dei dataset partizionati compressi;
- `orchestrate_benchmarks.py`: esecuzione batch sulle configurazioni $(n, d, seed)$ e selezione dei parametri per ogni algoritmo standard o custom.

L'esecuzione end-to-end della pipeline del framework è la seguente:

1. vengono prima generati i dataset, chiamati `dataset_n_{n}_d_{d}_p_{p}_s_{seed}.bin` tramite lo script Python di generazione (`scripts/generate_partitioned_dataset_bin.py`);
2. viene eseguito poi da CLI il (`main.cpp`) e vengono configurati i parametri rimanenti per ogni algoritmo, tra cui la modalità di esecuzione;
3. l' `EvaluationFramework` gestisce il parsing del dataset e gli algoritmi vengono eseguiti;
4. infine, a seconda della modalità, avviene la scrittura CSV in `results/<algorithm>/<params>/results_*.csv` con `PathUtils::buildResultCsvPath` e `CsvResultWriter`.

4.2 DATASET

I dataset generati sono sintetici significa che non c'è alcun dato reale. Un dataset è composto da un'intestazione in cui sono presenti i seguenti parametri:

- n : numero di elementi per ogni partizione;
- d : numero di elementi distinti per ogni partizione;
- p : numero di partizioni;
- $seed$: il seed che ha generato questo dataset.

Subito dopo iniziano le partizioni, ogni partizione è composta da n righe in cui sono presenti d numeri unici. In ogni riga delle partizioni abbiamo l'elemento seguito da un bit.

Questo bit vale 1 se l'elemento è la prima volta che appare nella partizione, o se è già apparso. Di conseguenza la somma di tutti i bit è uguale a d .

Inoltre, il dataset è in un formato binario, il quale dopo essere stato generato viene pure compresso.

4.2.1 MOTIVAZIONE DEL FORMATO

Poiché gli algoritmi di sketching sono generalmente utilizzati con i big data, i cui dati non vengono effettivamente memorizzati su disco, si è dovuto scegliere un formato che permettesse di salvare su file i vari dataset.

Il motivo di dover salvare su disco il dataset è per motivi di riproducibilità, analisi e valutazione degli algoritmi.

Precedentemente è stato definito che all'interno di un dataset sono presenti più partizioni. K'idea che sta dietro a questa scelta è che così facendo, si può materializzare in memoria un'unica partizione dell'intero dataset durante la valutazione alla volta. Ogni partizione è compressa indipendentemente con `zlib`; il framework carica solo il blocco necessario alla run corrente tramite `BinaryDatasetPartitionReader` in (`BinaryDatasetIO.h`).

4.2.2 STRUTTURA DEL FILE

Il file contiene: un header globale, la tabella delle partizioni e dei payload compressi. I parametri di formato sono codificati in `BinaryDatasetIO.h` e nello script generatore.

Campo header	Significato
MAGIC=SATPDBN2	Identificatore formato
VERSION=2	Versione schema
n	Elementi per partizione
d	Distinti per partizione
p	Numero di partizioni
seed	Seed globale del dataset

Tabella 4.1: Campi principali dell'header del dataset binario.

Ogni entry della tabella partizioni (`ENTRY_SIZE=60*`) contiene:

- `values_offset, values_byte_size;`
- `truth_offset, truth_byte_size;`
- `n, d` locali (validati contro l'header globale);
- codifiche `values_encoding` e `truth_encoding`, rispettivamente `ENCODING_ZLIB_U32_LE` e `ENCODING_ZLIB_BITSET_LE`.

4.2.3 BITSET DI VERITÀ PER $F_0(t)$

Come accennato poc'anzi, per ogni partizione, oltre ai valori `uint32` compressi, viene salvato un bitset compresso in cui il bit t vale 1 se l'elemento in posizione t è una prima occorrenza nella partizione. Nel framework di streaming il numero di elementi distinti prefissato è ricostruito con l'accumulo:

$$F_0(t) = \sum_{i=1}^t b_i.$$

Questa scelta evita la ricostruzione di insiemi espliciti durante la valutazione prefisso per prefisso.

*La dimensione 60 deriva dal layout binario `<QQQQQQIII`. Nel formato `struct` di Python, Q indica un intero unsigned a 64 bit (`uint64_t`, 8 byte) e I indica un intero unsigned a 32 bit (`uint32_t`, 4 byte). Quindi: sei campi Q ($6 \times 8 = 48$) più tre campi I ($3 \times 4 = 12$), per un totale di $48 + 12 = 60$ byte. Il prefisso `<` impone little-endian standard senza padding.

4.2.4 INDICIZZAZIONE E CARICAMENTO PER PARTIZIONE

Il metodo `indexBinaryDataset` valida magic, versione, consistenza dei metadati, range degli offset e codifiche supportate; inoltre verifica che $d \leq n$.

La classe `BinaryDatasetPartitionReader` mantiene un file handle aperto e fornisce: `load(partitionIndex, outValues)` e `loadWithTruthBits(partitionIndex, outValues, outTruthBits)`.

Il costo in memoria è quindi proporzionale alla sola partizione corrente.

4.2.5 ESEMPIO

Per rendere esplicito il formato, consideriamo un dataset con:

$$n = 8, \quad d = 4, \quad p = 2, \quad seed = 42.$$

Supponiamo che, prima della compressione nella partizione 0, la stream sia:

t	valore x_t	bit b_t (prima occorrenza)	$F_0(t) = \sum_{i=1}^t b_i$
1	7	I	1
2	12	I	2
3	3	I	3
4	7	O	3
5	12	O	3
6	9	I	4
7	7	O	4
8	9	O	4

Tabella 4.2: Esempio logico di una partizione: valori e bit di verità.

In questo esempio gli elementi distinti della partizione sono $\{7, 12, 3, 9\}$, quindi $\sum_{t=1}^8 b_t = 4 = d$.

Il file contiene:

- header globale (MAGIC, VERSION, n , d , p , $seed$);
- tabella partizioni con 2 entry da 60 byte ciascuna;
- payload compressi (values e truth) per ogni partizione.

Per la partizione 0:

- values = array `uint32` dei valori $[7, 12, 3, 7, 12, 9, 7, 9]$, compresso con `zlib`;
- truth = bitset $[1, 1, 1, 0, 0, 1, 0, 0]$, compresso con `zlib` (in un byte: `0b00100111 = 0x27`, con bit in ordine LSB-first).

4.3 GENERAZIONE DATASET

Lo script `generate_partitioned_dataset_bin.py` permette il passaggio dei seguenti parametri `-n`, `-d`, `-p`, `-seed`, `-workers`, `-progress-batch`. I vincoli implementati sono:

$$0 \leq d \leq n, \quad d \leq \min(n, 2^{32}), \quad p > 0.$$

La nomenclatura del file di output è deterministica ed è stato scelto il seguente formato: `dataset_n_{n}_d_{d}_p_{p}_s_{seed}.bin`.

Per ogni partizione, il generatore:

1. deriva un seed locale da $(seed, partition_index)$ tramite `_derive_partition_seed`;
2. estrae d ID distinti nel dominio $[0, \min(n, 2^{32}) - 1]$;
3. forza d posizioni per garantire almeno una occorrenza per ogni ID distinto;
4. completa le altre posizioni campionando dagli ID distinti;
5. costruisce il bitset di prime occorrenze e comprime separatamente valori e bitset.

Quando il numero di workers è maggiore di 1, la generazione è parallelizzata per partizione con `multiprocessing`; la barra di avanzamento è emessa su `stderr`.

4.4 INTERFACCE COMUNI E HASHING

4.4.1 INTERFACCIA BASE DEGLI ALGORITMI

L'interfaccia comune degli algoritmi è definita in `Algorithm.h` e contiene i seguenti metodi:

- `process(uint32_t id)`: aggiorna lo sketch;
- `count()`: restituisce la stima corrente di F_0 ;
- `merge(const Algorithm& other)`: combina due sketch compatibili;
- `reset()`: azzeramento stato;
- `getName()`: nome algoritmo.

La modalità `runmerge` richiede, in particolare, la presenza di `merge` nell'algoritmo analizzato.

Nel framework è applicato un controllo di concetto (`detail::MergeableAlgorithm` in `EvaluationFramework.tpp`).

4.4.2 HASHING UNIFORME NEL CODICE

La randomizzazione è centralizzata in `hashing.h` e contiene due metodi:

- `splitmix64(uint64_t)` come funzione di hash a 64 bit;
- `hash32_from_64(uint64_t)` per derivare il dominio 32 bit.

La scelta dietro a questa funzione di hash a 32 bit derivata dalla funzione a 64 bit è per non avere una funzione di hash completamente diversa da quella già esistente per gli algoritmi con un hash più corta.

HyperLogLog e LogLog applicano `hash32_from_64`; HyperLogLog++ usa direttamente il valore a 64 bit.

4.5 IMPLEMENTAZIONE DEGLI ALGORITMI

Ogni algoritmo segue lo pseudocodice dei relativi autori in [14, 15, 16, 17, 18, 19].

4.5.1 PROBABILISTICCOUNTING

Seguendo lo pseudocodice in [14], `ProbabilisticCounting` accetta $L \in [1, 31]$, altrimenti solleva un eccezione: `invalid_argument`. L'aggiornamento imposta il bit corrispondente alla posizione del primo 1 da destra (`count_zero`) su hash troncato a L bit; la stima usa l'indice del primo zero (`count_one`) e la costante ϕ nel termine $\propto 2^R$ [14].

L'operazione di merge è un OR bit per bit con vincolo di compatibilità su L .

4.5.2 LOGLOG

L'algoritmo `LogLog` segue lo pseudocodice in [15]:

- $k \in [4, 16]$;
- $L = 32$ obbligatorio.

Il merge richiede gli stessi (k, L) e applica la funzione del massimo componente per componente sui registri.

4.5.3 HYPERLOGLOG

In [16] `HyperLogLog` impone che $k \in [4, 16]$ e $L = 32$.

Il merge richiede, come per i precedenti algoritmi, uguaglianza di (k, L) e combina i registri con il massimo componente per componente.

La funzione `count()` varia a seconda di tre regimi di dimensionalità quando è in:

- *small-range* con il linear counting;
- *raw-range* con la stima armonica;
- *large-range* con la correzione logaritmica su 2^{32} .

In accordo con [16].

4.5.4 HYPERLOGLOG++

Per quanto riguarda HyperLogLogPlusPlus, sempre seguendo [17], impone $p \in [4, 18]$ e l'uso di una funzione di hash a 64 bit. L'algoritmo utilizza uno stato interno che viene alternato in due formati:

- *sparse*: lista compressa di coppie codificate indice/ p ;
- *normal*: vettore registri denso.

Il passaggio da *sparse* a *normal* segue il costo del confronto della codifica sparsa (`sparseBits()`) e il costo della codifica densa (`denseBits()`).

La stima finale usa una tabella di bias (`hllpp_tables`) e di soglia `threshold_for_k(p)` per scelta tra linear counting e stima corretta.

La tabella è stata presa dalla documentazione ufficiale da [17].

Il merge richiede di avere lo stesso p . Questa scelta segue sempre [17].

4.5.5 VERIFICA DEI DOMINI PARAMETRICI

I domini accettati sono verificati durante la costruzione dell'oggetto. I test in `tests/algorithms/*.cpp` coprono esplicitamente i bound di HyperLogLog++, HyperLogLog e LogLog; per ProbabilisticCounting coprono il comportamento di merge e la compatibilità dei parametri:

- HyperLogLog++: $p \in [4, 18]$;
- HyperLogLog: $k \in [4, 16]$, $L = 32$;
- LogLog: $k \in [4, 16]$, $L = 32$;
- ProbabilisticCounting: $L \in [1, 31]$.

Lo script `orchestrate_benchmarks.py` replica gli stessi domini nelle modalità `-full` e `single-params`.

4.6 FRAMEWORK DI VALUTAZIONE

Nel framework di valutazione esistono 3 modalità di valutazione dei risultati. Questo per consentire l'utilizzo degli algoritmi in maniere differenti, in seguito vengono spiegate in maniera dettagliata.

Il framework permette di monitorare determinate metriche che sono aperte ad essere aggiunte. In maniera consona le metriche di output sono le stesse che vengono monitorate.

4.6.1 MODALITÀ *normal*, *streaming*, *merge*

Le tre modalità operative del framework sono:

- *normal*: per ogni partizione si esegue una run completa dell'algoritmo, si calcola la stima finale \hat{F}_0 e si aggregano le metriche su tutte le run (una run per partizione). È la modalità di test.

- **streaming**: per ogni partizione si processa la stream elemento per elemento. A checkpoint prefissati t , si salvano stima e verità di prefisso, poi si aggregano le metriche tra run per ciascun checkpoint. La verità $F_0(t)$ è ricostruita dal bitset di prime occorrenze:

$$F_0(t) = \sum_{i=1}^t b_i.$$

- **merge**: le partizioni sono accoppiate a due a due $(0, 1), (2, 3), \dots$. Per ogni coppia si costruiscono due sketch separati (S_A, S_B) , si calcola lo sketch mergiato $S_M = S_A \oplus S_B$, e si confronta con uno sketch seriale S_{serial} ottenuto processando in sequenza le due partizioni. Le metriche di confronto sono:

$$\Delta_{abs} = \left| \hat{F}_{0,merge} - \hat{F}_{0,serial} \right|, \quad \Delta_{rel} = \frac{\Delta_{abs}}{\hat{F}_{0,serial}}$$

(se $\hat{F}_{0,serial} = 0$, nel codice $\Delta_{rel} = 0$).

La classe `EvaluationFramework` espone tre flussi:

- `evaluateToCsv(...)` per endpoint per partizione (`mode=normal`);
- `evaluateStreamingToCsv(...)` per checkpoint prefissati (`mode=streaming`);
- `evaluateMergePairsToCsv(...)` per confronto merge vs seriale su coppie (`mode=merge`).

Nel backend binario, `runs` e `sample_size` sono derivati dai metadati del dataset tramite `datasetScope()`. In modalità `merge`, il numero effettivo di coppie è $\lfloor \text{runs}/2 \rfloor$.

4.6.2 METRICHE IMPLEMENTATE

Le metriche sono aggregate da `ErrorAccumulator` in coerenza con le definizioni statistiche introdotte nel Capitolo 2 (stimatori e metriche d'errore). Indicando con R il numero di run, con $\hat{F}_0^{(r)}(t)$ la stima alla run r e checkpoint t , e con $F_0^{(r)}(t)$.

Nel CSV, i nomi delle colonne corrispondono a:

- `mean` = $\bar{\hat{F}}_0(t)$
- `truth_mean` = $\bar{F}_0(t)$
- `variance` = $\widehat{\text{Var}}(t)$
- `stddev` = $\widehat{\sigma}(t)$
- `bias` = $\text{Bias}(t)$
- `absolute_bias` = $|\text{Bias}(t)|$
- `relative_bias` = $\text{RelBias}(t)$
- `mean_relative_error` = $\text{MRE}(t)$
- `mae` = $\text{MAE}(t)$
- `rmse` = $\text{RMSE}(t)$

- $\text{rse_observed} = \text{RSE}_{\text{obs}}(t)$

In `AlgorithmExecutor.cpp` il valore teorico è impostato come:

$$\text{RSE}_{\text{theo}} = \frac{1.04}{\sqrt{m}} (\text{HyperLogLog}, \text{HyperLogLog++}), \quad \text{RSE}_{\text{theo}} = \frac{1.30}{\sqrt{m}} (\text{LogLog}),$$

con $m = 2^k$. Per Probabilistic Counting viene scritto NaN.

4.6.3 CHECKPOINT IN MODALITÀ STREAMING

I checkpoint sono costruiti da `StreamingCheckpointBuilder::build(n, K)` con $n = \text{sample_size}$ e $K =$ numero massimo target di checkpoint (default $K = 200$).

Se $n \leq K$, si usano tutti i prefissi:

$$\mathcal{T} = \{1, 2, \dots, n\}.$$

Se $n > K$, si usa una strategia ibrida su tre fasi:

$$[0, 0.1\%] \text{ (lineare)}, \quad (0.1\%, 10\%] \text{ (log)}, \quad (10\%, 100\%] \text{ (log)}.$$

Sia

$$n_1 = \lceil 10^{-3}n \rceil, \quad p_1 = 10^{-3}, \quad p_2 = 10^{-1}.$$

Dopo avere fissato il checkpoint $t = 1$, i checkpoint rimanenti sono ripartiti circa 50%, 30%, 20% tra le tre fasi.

FASE 1 (LINEARE) Per $i = 1, \dots, k_1$:

$$t_i^{(1)} = \left\lceil \frac{i n_1}{k_1} \right\rceil.$$

FASE 2 (LOGARITMICA IN PERCENTUALE) Per $i = 1, \dots, k_2$:

$$\pi_i^{(2)} = p_1 \left(\frac{p_2}{p_1} \right)^{i/k_2}, \quad t_i^{(2)} = \left\lceil \pi_i^{(2)} n \right\rceil.$$

FASE 3 (LOGARITMICA IN PERCENTUALE) Per $i = 1, \dots, k_3$:

$$\pi_i^{(3)} = p_2 \left(\frac{1}{p_2} \right)^{i/k_3}, \quad t_i^{(3)} = \left\lceil \pi_i^{(3)} n \right\rceil.$$

Infine i checkpoint vengono ordinati, deduplicati e si forza sempre il punto finale $t = n$.

4.6.4 OUTPUT CSV

Le modalità `normal` e `streaming` condividono lo stesso schema CSV dove ogni colonna è:

- `algorithm`: nome dell'algoritmo (es. HyperLogLog++, HyperLogLog, LogLog, Probabilistic Counting).

- `params`: parametri effettivi della configurazione (es. $k=16$, $L=32$, $L=23$).
- `mode`: modalità di esecuzione (`normal`, `streaming`, `merge`).
- `runs`: numero di run aggregate (coincide con il numero di partizioni del dataset).
- `sample_size`: numero di elementi per partizione (n).
- `number_of_elements_processed`: numero di elementi già processati nella run corrente; in `normal` vale n , in `streaming` coincide con il checkpoint t .
- `f0`: cardinalità distinta nominale del dataset (d , uguale per partizione).
- `seed`: seed del dataset letto dal file binario.
- `f0_mean_t`: verità media aggregata al tempo t , cioè $\bar{F}_0(t)$.
- `f0_heat_mean_t`: stima media aggregata al tempo t , cioè $\hat{\bar{F}}_0(t)$.
- `variance`: varianza campionaria della stima al tempo t , $\widehat{\text{Var}}(t)$.
- `stddev`: deviazione standard campionaria, $\hat{\sigma}(t)$.
- `rse_theoretical`: RSE teorica assegnata alla famiglia algoritmica (se disponibile).
- `rse_observed`: RSE osservata, $\hat{\sigma}(t)/\bar{F}_0(t)$.
- `bias`: bias osservato, $\hat{\bar{F}}_0(t) - \bar{F}_0(t)$.
- `absolute_bias`: valore assoluto del bias, $|\text{Bias}(t)|$.
- `relative_bias`: bias relativo, $\text{Bias}(t)/\bar{F}_0(t)$.
- `mean_relative_error`: errore relativo medio, $\text{MRE}(t)$.
- `rmse`: root mean squared error al tempo t , $\text{RMSE}(t)$.
- `mae`: mean absolute error al tempo t , $\text{MAE}(t)$.

La modalità `merge` mantiene lo stesso blocco descrittivo iniziale (`algorithm`, `params`, `mode`, `sample_size`, `seed`), ma sostituisce il blocco delle metriche di stima con colonne specifiche del confronto *merge vs seriale*:

```
pairs, pair_index, estimate_merge, estimate_serial,
delta_merge_serial_abs, delta_merge_serial_rel
```

dove `estimate_merge` è la stima dopo fusione dei due sketch, `estimate_serial` è la stima ottenuta processando serialmente la stessa coppia, e i due `delta` misurano lo scostamento assoluto e relativo tra i due risultati.

4.7 CLI E ORCHESTRAZIONE SPERIMENTALE

4.7.1 CLI INTERATTIVA

L'entry point è il `main.cpp` che istanzia `BenchmarkCli`. I comandi sono:

- `help`: mostra l'elenco dei comandi disponibili e una breve descrizione d'uso.
- `show`: stampa la configurazione corrente; `sampleSize`, `runs` e `seed` sono letti dal dataset indicato in `datasetPath`.
- `list`: elenca gli algoritmi disponibili (`hllpp`, `hll`, `ll`, `pc`).
- `set <param> <value>`: imposta un parametro della sessione. I parametri supportati sono `datasetPath`, `k`, `l`, `llog`.
- `run <algo|all>`: esegue uno o più algoritmi in modalità `normal` (metriche all'endpoint $t = n$).
- `runstream <algo|all>`: esegue uno o più algoritmi in modalità `streaming` (metriche ai checkpoint t durante la scansione della partizione).
- `runmerge <algo|all>`: esegue benchmark di merge a coppie di partizioni $(0, 1)$, $(2, 3)$, \dots , confrontando stima da merge e stima seriale.
- `quit`: termina la sessione interattiva.

Per i comandi `run`, `runstream` e `runmerge`, l'argomento `<algo>` può essere uno tra `hllpp`, `hll`, `ll`, `pc`, oppure `all`.

Il metodo `PathUtils::buildResultCsvPath` costruisce i percorsi:

- `results/<AlgorithmName>/<params>/results_oneshot.csv`;
- `results/<AlgorithmName>/<params>/results_streaming.csv`;
- `results/<AlgorithmName>/<params>/results_merge.csv`.

La stringa `params` viene sanitizzata da `sanitizeForPath` sostituendo i caratteri non alfanumerici con `_`.

4.7.2 ORCHESTRAZIONE BATCH

Lo script `orchestrate_benchmarks.py` automatizza:

- pianificazione della matrice $(n, d, seed)$ e numero partizioni p ;
- generazione dataset (opzionale) con `ensure_dataset`;
- invio di payload CLI con sequenze `set + run/runstream/runmerge`;
- i parametri di default, se non vengono passati esplicitamente con l'opzione `(-full)` su domini validi.

Per l'analisi finale del Capitolo 5, i grafici e le tabelle sono prodotti in modo riproducibile all'interno di notebooks Jupyter.

4.8 SEED E RIPRODUCIBILITÀ

Il seed viene definito all'interno del dataset e viene propagato all'interno dell'intero framework. La sua propagazione segue questo flusso:

1. il generatore scrive il seed nell'header binario in `generate_partitioned_dataset_bin.py`;
2. il metodo `indexBinaryDataset` legge il campo e lo valida nel dominio `uint32`;
3. il metodo `CliConfig::loadDatasetRuntimeContext` trasferisce il seed nel contesto runtime `DataSetRuntimeContext`;
4. il `EvaluationFramework` copia `binaryDataset.info.seed` nel membro `seed`;
5. infine il `CsvResultWriter` serializza il seed in tutte le righe `normal/streaming/merge`.

Inoltre, la generazione usa `_derive_partition_seed(seed, partition_index)` per rendere deterministico il contenuto di ogni partizione.

4.9 VALIDAZIONE E TESTING

La suite principale di test è presente in `tests/` e utilizza un dataset fisso `dataset_n_2000_d_1000_p_3_s_5489.bin`.

4.9.1 TEST ALGORITMICI C++

In `tests/algorithms` sono presenti test per:

- un semplice test di accuratezza per HLL, HLL++, LogLog e ProbabilisticCounting su dataset di riferimento;
- la validazione dei domini parametrici su HLL, HLL++ e LogLog;
- le proprietà di merge (serialità/commutatività/idempotenza), con controllo esatto per HLL, LogLog e ProbabilisticCounting e tolleranza relativa per HLL++;
- la verifica di compatibilità dei parametri in modalità di merge (eccezioni su mismatch).

4.9.2 TEST FRAMEWORK

Il test del framework `EvaluationFrameworkTest.cpp` verifica che:

- i valori siano definiti e il segno sia non negativo delle metriche principali;
- in streaming con `NaiveCounting` sia uguale a $\hat{F}_0(t) = F_0(t)$ a ogni checkpoint;
- la correttezza delle policy di checkpoint (che abbia un inizio, che sia monotona crescente e che la terminazione sia n);
- la correttezza del percorso delle coppie di merge e del loro relativo CSV.

4.IO SCELTE PROGETTUALI E LIMITI ATTUALI

Per esplicitare in un'unica sezione le scelte progettuali, esse sono:

- la separazione netta tra gli algoritmi, l'I/O e il framework di misura;
- il formato binario compresso con loader per singola partizione;
- le tre modalità di run (normal, streaming, merge);
- la serializzazione CSV con uno schema stabile e una colonna per il seed in ogni record.

4.II TODOs

- mancano le implementazioni Count-Min Sketch, Bloom Filter e Ring Bloom Filter
- assenza di un test dedicato ai limiti di costruzione di ProbabilisticCounting ($L \in [1, 31]$);
- i report CSV includono metriche aggregate ma non esportano ancora serie per-run complete per tutte le modalità di analisi avanzata.

5

Risultati sperimentali

In questo capitolo presenta i risultati sperimentali finali ottenuti con il framework descritto nel Capitolo 4. L'analisi è limitata alle modalità di *streaming* e di *merge*, mentre i file *oneshot* non vengono utilizzati poiché, a differenza, della modalità streaming viene preso un solo risultato finale per esecuzione. Le metriche considerate sono quelle formalizzate nel Capitolo 2.

5.1 AMBIENTE DI TEST

I risultati sperimentali sono stati ottenuti su un notebook Apple MacBook Pro 13" (2020) con processore Apple M1 (Apple Silicon) con 16 GB di memoria RAM, un SSD NVMe da 512 GB e macOS Sequoia 15.7.2.

L'esecuzione è avvenuta localmente su singola macchina, senza distribuzione su più nodi.

La build e l'esecuzione dei test sono state effettuate con la seguente toolchain:

- CMake 4.2.3;
- Apple Clang 17.0.0 (clang-1700.0.13.5);
- target compilazione: arm64-apple-darwin24.6.0.

5.1.1 CONFIGURAZIONE SPERIMENTALE

I risultati sono stati estratti dai CSV presenti in `results/` con la seguente configurazione:

- $n = 10^7$ elementi per partizione;
- $F_0 \in \{10^5, 10^6, 5 \cdot 10^6, 10^7\}$;

- $\text{seed} \in \{42, 137357, 10032018, 21041998, 29042026\}$;
- 50 run per ogni dataset.

Ottenendo un totale di 72 file di `results_streaming.csv` e `results_merge.csv`.

La produzione delle figure e delle tabelle è stata ottenuta tramite l'utilizzo di notebook Jupyter per riproducibilità all'interno della cartella `notebooks`.

5.2 SELEZIONE DELLE CONFIGURAZIONI MIGLIORI

Uno dei principali problemi di tutte queste possibili configurazioni dei parametri per ogni algoritmo è stato di individuare quali fossero i parametri ottimali.

Il confronto principale è avvenuto fissando, per ciascun algoritmo, il parametro che minimizza il *mean relative error* medio al checkpoint finale (aggregazione su seed e valori di F_0). I parametri individuati sono riportati nella Tabella 5.1.

Algoritmo	Parametro migliore	MRE medio endpoint
HyperLogLog	$k = 16$	0.002736
HyperLogLog++	$k = 18$	0.001370
LogLog	$k = 15$	0.005615
Probabilistic Counting	$L = 23$	0.524951

Tabella 5.1: Configurazione ottimale per algoritmo nel dominio esplorato.

5.3 CONFRONTO TRA I VARI SEED

Per poter fare le analisi successive si è fatta prima un'analisi sperimentale per verificare che scegliere un seed rispetto ad un altro non cambi le valutazioni degli algoritmi in maniera gravosa.

L'analisi è stata eseguita fissando, per ciascun algoritmo, la configurazione ottimale della Tabella 5.1 e confrontando i seed $\{42, 137357, 10032018, 21041998, 29042026\}$ sui valori finali di `results_streaming.csv`. Per misurare la sensibilità al seed è stato utilizzato il coefficiente di variazione

$$CV(X) = \frac{\sigma(X)}{|\mathbb{E}[X]|},$$

calcolato su MRE, RMSE, varianza e bias.

Il CV è una misura *adimensionale* di dispersione relativa: valori vicini allo 0 indicano che la metrica varia poco al variare del seed, mentre valori più alti indicano maggiore sensibilità. In seguito si usa la seguente lettura operativa: $CV < 0.10$ indica una variabilità contenuta, $0.10 \leq CV < 0.20$ una variabilità moderata, mentre $CV \geq 0.20$ una variabilità elevata.

Queste soglie sono interpretative (non universali) e vanno sempre lette insieme al livello assoluto dell'errore: una configurazione può avere CV basso ma avere un errore medio alto.

Inoltre, quando $|\mathbb{E}[X]|$ è molto vicino a zero, il CV può diventare numericamente instabile; in questi casi la valutazione è supportata anche da boxplot e metriche assolute.

La Figura 5.1 mostra i valori di CV per configurazione algoritmica, mentre la Figura 5.2 riporta la distribuzione della MRE sui seed per le configurazioni selezionate.




Figura 5.1: Sensibilità al seed: coefficiente di variazione della MRE per setting algoritmico.

La Tabella 5.2 sintetizza i risultati principali. HyperLogLog e HyperLogLog++ mostrano una sensibilità simile e contenuta ($CV_{MRE} \approx 0.079$); LogLog è leggermente più sensibile (≈ 0.116). Mentre Probabilistic Counting presenta un CV_{MRE} molto basso, ma con MRE assoluta elevata (circa 0.5 nella configurazione ottimale), ricordando che “stabile” non implica “accurato”.

Algoritmo	Parametri (seed-sensitivity)	CV_{MRE}
HyperLogLog	$k = 7, L = 32$	0.079052
HyperLogLog++	$k = 7$	0.079061
LogLog	$k = 8, L = 32$	0.116134
Probabilistic Counting	$L = 1$	8.53×10^{-6}

Tabella 5.2: Sintesi della sensibilità al seed (metrica: coefficiente di variazione della MRE).

In base a questo confronto, i seed scelti non alterano in modo sostanziale la stima qualitativa tra gli algoritmi nelle configurazioni selezionate. Di conseguenza, le analisi successive possono essere discusse su un unico seed




Figura 5.2: Distribuzione della MRE sui seed nelle configurazioni ottimali.

rappresentativo, in questo caso si è scelto 21041998, senza perdita di generalità operativa, mantenendo comunque i risultati aggregati sui seed nelle tabelle riepilogative.

5.4 RISULTATI STREAMING CON LE CONFIGURAZIONI OTTIMALI

Una volta individuati i parametri che minimizzassero la *mean relative error* si è fatta un'analisi sulla stima media di F_0 tra i vari algoritmi utilizzando un unico seed.

5.4.1 STIMA MEDIA NEL TEMPO E TRANSITORIO INIZIALE

Le figure 5.3 e 5.4 mostrano l'andamento di $\hat{F}_0(t)$ rispetto a $F_0(t)$ con seed 21041998. La scala log-log è usata per rendere visibile il comportamento sui primi checkpoint.

In questa configurazione HyperLogLog++ e HyperLogLog seguono da vicino la curva reale su tutti i livelli di cardinalità testati. L'algoritmo LogLog rimane comunque vicino ai due algoritmi HLL per F_0 medio-alti, ma mantiene uno scarto più evidente nel caso $F_0 = 10^5$. Mentre Probabilistic Counting resta l'algoritmo meno stabile nella fase transitoria, con deviazioni significative già a metà stream.




Figura 5.3: Configurazione ottimale: confronto tra stima media $\hat{F}_0(t)$ e valore reale $F_0(t)$ in scala lineare (seed 21041998).




Figura 5.4: Stesso confronto della Figura 5.3 in scala log-log.

5.4.2 VARIANZA NEL TEMPO

La figura 5.5 confronta la varianza della stima in scala log-log.

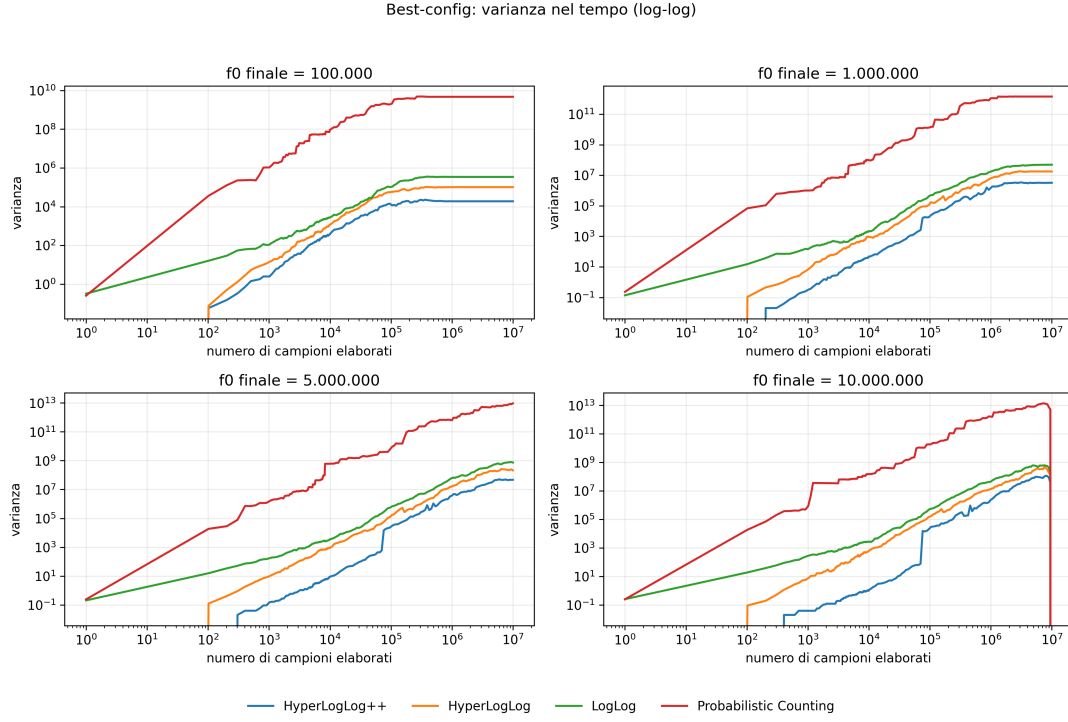


Figura 5.5: Configurazione ottimale: varianza della stima in modalità streaming (seed 21041998, scala log-log).

La dispersione di HyperLogLog++ è inferiore a HyperLogLog e LogLog per quasi l'intero dominio osservato, in coerenza con la progettazione di HLL++ [17]. Per $F_0 = 10^7$ la varianza endpoint è nulla per tutte le configurazioni ottimali perché nel dataset usato vale $n = d$ e l'endpoint è deterministico tra run.

5.4.3 METRICHE AGGREGATE IN MODALITÀ *NORMAL*

La Tabella 5.3 riporta le metriche associate alla modalità di esecuzione *normal* mediate sui seed per ciascun valore finale di F_0 .

La Figura 5.6 visualizza lo stesso confronto sull'unica metrica MRE.

5.5 RISULTATI MERGE CON LA CONFIGURAZIONE OTTIMALE

Per ogni algoritmo si confrontano stima da merge e stima seriale su coppie di partizioni. Le Figure 5.7 e 5.8 e la Tabella 5.4 mostrano che nel dominio sperimentale analizzato i delta sono nulli in tutti i casi. Il risultato è coerente

Algoritmo	F_0	MRE medio	RMSE medio	Varianza media	\hat{F}_0 medio
HyperLogLog++	100000	0.001237	153.661	22550.603	99990.816
HyperLogLog++	1000000	0.001629	2026.870	3272587.016	1000904.100
HyperLogLog++	5000000	0.001287	8072.642	62887388.036	5001168.396
HyperLogLog++	10000000	0.001326	13256.000	0.000	10013256.000
HyperLogLog	100000	0.002836	358.238	127585.802	100008.844
HyperLogLog	1000000	0.003195	3938.423	15118314.694	999213.888
HyperLogLog	5000000	0.002800	17416.878	278970064.540	4994349.692
HyperLogLog	10000000	0.002113	21134.000	0.000	9978866.000
LogLog	100000	0.005206	649.431	407725.504	100124.060
LogLog	1000000	0.005390	6789.407	46105629.058	999245.028
LogLog	5000000	0.004713	28669.821	699006423.800	4988366.864
LogLog	10000000	0.007150	71500.000	0.000	9928500.000
Probabilistic Counting	100000	0.579277	79492.780	6139769255.600	117344.080
Probabilistic Counting	1000000	0.911951	1321697.966	1418662093360.000	1646384.880
Probabilistic Counting	5000000	0.524089	3231428.510	10582138707400.000	5210955.228
Probabilistic Counting	10000000	0.084486	844860.000	0.000	10844860.000

Tabella 5.3: Configurazione ottimale: metriche endpoint aggregate in modalità streaming (media sui seed).

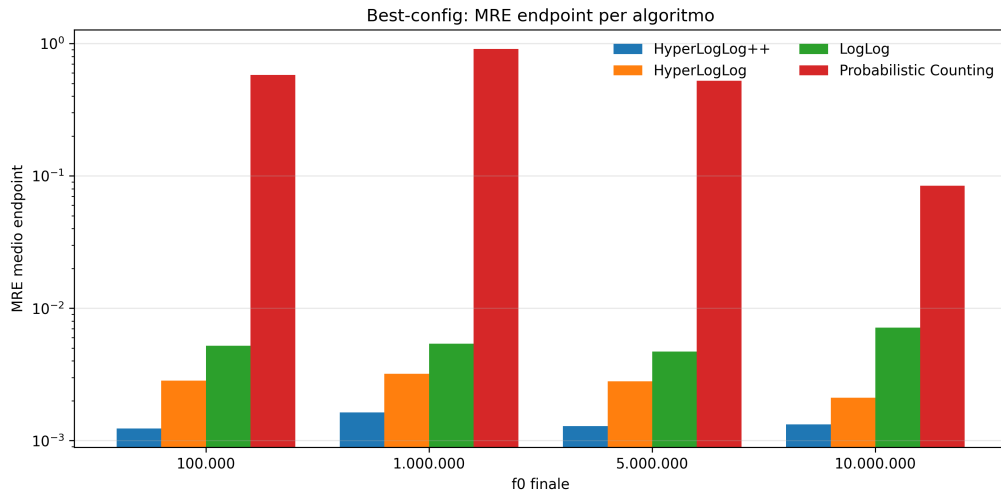


Figura 5.6: Configurazione ottimale: MRE endpoint per algoritmo e valore finale di F_0 (media sui seed).

con gli operatori di merge implementati (massimo componente-per-componente per LogLog/HLL/HLL++ e OR bit-a-bit per Probabilistic Counting), discussi in Capitolo 4 e nel background sulla mergeabilità.




Figura 5.7: Configurazione ottimale: distribuzione di delta_merge_serial_abs.




Figura 5.8: Configurazione ottimale: conteggio dei casi con delta non nullo nel confronto merge vs seriale.

5.6 DISCUSSIONE

Nel dominio sperimentale considerato emergono tre risultati principali. Primo, HyperLogLog++ risulta il metodo più accurato e stabile tra le configurazioni migliori, con errore medio endpoint inferiore a HyperLogLog e LogLog su tutti i livelli di F_0 osservati. Secondo, LogLog resta competitivo ma con una dispersione più alta e una sensibilità maggiore nelle cardinalità più piccole. Terzo, Probabilistic Counting rimane sensibilmente più instabile, anche quando si seleziona il miglior parametro nel dominio testato.

Algoritmo	Righe	Media Δ_{abs}	Max Δ_{abs}	Media Δ_{rel}	Max Δ_{rel}
HyperLogLog	500	0	0	0	0
HyperLogLog++	500	0	0	0	0
LogLog	500	0	0	0	0
Probabilistic Counting	500	0	0	0	0

Tabella 5.4: Configurazione ottimale: confronto merge vs seriale. Tutti i delta risultano nulli nel dataset analizzato.

Per la modalità merge, i risultati sono coerenti con la proprietà di fusione attesa per gli sketch implementati: nel confronto a coppie non si osservano scarti rispetto al processamento seriale.

5.7 TODOs

I limiti principali della campagna corrente sono:

- un solo valore di n nella fase finale (10^7);
- un unico profilo dati (distribuzione uniforme, ordine shuffled);
- assenza in questo capitolo di misure esplicite di costo temporale e footprint di memoria a runtime.

Un'estensione naturale è replicare la stessa analisi su distribuzioni non uniformi e su workload con overlap controllato tra partizioni, mantenendo il medesimo protocollo di confronto tra endpoint, transitorio e merge.

6

Conclusioni

Volendo idea: sarebbe da prendere i dati in una stream continua e fare misurazione real-time di quello che accade, ovviamente non si può sapere il valore esatto in questo caso.

Pero' si potrebbe invece fare che la stream esiste già' pero' vengono dati un valore alla volta, in modo tale da avere effettivamente i valori.

Pensare anche all'implementazione di un sistema reale di streaming di dati come Apache Kafka.

Bibliografia

- [1] J. Leskovec, A. Rajaraman, and J. D. Ullman, *Mining Data Streams*. Cambridge University Press, 2014, p. 123–153.
- [2] S. Muthukrishnan, “Data streams: Algorithms and applications,” Rutgers University, Tech. Rep., 2005.
- [3] Z. Bar-Yossef, T. S. Jayram, R. Kumar, D. Sivakumar, and L. Trevisan, “Counting distinct elements in a data stream,” in *Randomization and Approximation Techniques in Computer Science (RANDOM 2002)*, ser. Lecture Notes in Computer Science, vol. 2483. Springer, 2002, pp. 1–10.
- [4] D. M. Kane, J. Nelson, and D. P. Woodruff, “An optimal algorithm for the distinct elements problem,” in *Proceedings of the 29th ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems (PODS 2010)*. ACM, 2010.
- [5] G. Cormode, “Data sketching,” *Communications of the ACM*, 2017.
- [6] N. Prezza, “Algorithms for massive data – lecture notes,” 2025, lecture notes, Ca’ Foscari University of Venice.
- [7] R. M. Karp, “On-line algorithms versus off-line algorithms: How much is it worth to know the future?” in *IFIP Congress (1)*. World Computer Congress, 1992, pp. 416–429.
- [8] M. Datar, A. Gionis, P. Indyk, and R. Motwani, “Maintaining stream statistics over sliding windows: (extended abstract),” in *Proceedings of the Thirteenth Annual ACM-SLAM Symposium on Discrete Algorithms*, ser. SODA ’02. USA: Society for Industrial and Applied Mathematics, 2002, pp. 635–644.
- [9] P. K. Agarwal, G. Cormode, Z. Huang, J. M. Phillips, Z. Wei, and K. Yi, “Mergeable summaries,” in *Proceedings of the 31st ACM SIGMOD-SIGACT-SIGAI Symposium on Principles of Database Systems (PODS 2012)*. ACM, 2012.
- [10] S. Vadhan and M. Mitzenmacher, “Why simple hash functions work: Exploiting the entropy in a data stream,” 2007, manuscript.
- [11] A. Pagh and R. Pagh, “Uniform hashing in constant time and optimal space,” 2007, manuscript.
- [12] J. L. Carter and M. N. Wegman, “Universal classes of hash functions,” *Journal of Computer and System Sciences*, vol. 18, pp. 143–154, 1979.
- [13] S. van de Geer, “Mathematical statistics,” 2015, lecture notes, September 2015.
- [14] P. Flajolet and G. N. Martin, “Probabilistic counting algorithms for data base applications,” *Journal of Computer and System Sciences*, vol. 31, no. 2, 1985.

- [15] M. Durand and P. Flajolet, “Loglog counting of large cardinalities,” in *Proceedings of the European Symposium on Algorithms (ESA 2003)*, 2003.
- [16] P. Flajolet, É. Fusy, O. Gandouet, and F. Meunier, “Hyperloglog: the analysis of a near-optimal cardinality estimation algorithm,” in *Proceedings of the 2007 Conference on Analysis of Algorithms (AofA 07)*, 2007, pp. 127–146.
- [17] S. Heule, M. Nunkesser, and A. Hall, “Hyperloglog in practice: Algorithmic engineering of a state of the art cardinality estimation algorithm,” in *Proceedings of the International Conference on Extending Database Technology (EDBT/ICDT ’13)*. ACM, 2013.
- [18] G. Cormode, “Count-min sketch,” 2010, encyclopedia entry; local source: thesis/figures/cmencyc.pdf.
- [19] B. H. Bloom, “Space/time trade-offs in hash coding with allowable errors,” *Communications of the ACM*, vol. 13, no. 7, pp. 422–426, 1970.
- [20] S. Agarwal and A. Trachtenberg, “Approximating the number of differences between remote sets,” 2006, technical report/manuscript; local source: thesis/figures/bloom.pdf.
- [21] N. Alon, Y. Matias, and M. Szegedy, “The space complexity of approximating the frequency moments,” *Journal of Computer and System Sciences*, vol. 58, no. 1, pp. 137–147, 2002.
- [22] R. Motwani and P. Raghavan, “Randomized algorithms,” *ACM Computing Surveys*, vol. 28, no. 1, March 1996, copyright 00a9 1996, CRC Press.

Ringraziamenti