

Stima della cardinalità nei flussi di dati distribuiti: merge e compatibilità semantica degli algoritmi di sketch

Seminario di tesi magistrale

Daniele Ferroli

Università degli Studi di Udine

A.A. 2024–2025

- ① Motivazione, domanda di ricerca e contributi
- ② Background essenziale sugli sketch count-distinct
- ③ Disegno sperimentale e infrastruttura
- ④ Risultati sul comportamento in streaming
- ⑤ Risultati sul merge distribuito
- ⑥ Conclusioni, limiti e sviluppi futuri

Problema e motivazione

- Il problema riguarda la stima degli **elementi distinti** che compaiono in un flusso di dati continuo.
- Il conteggio esatto diventa rapidamente costoso in memoria e tempo quando il numero di elementi distinti cresce e la risposta deve essere aggiornata con bassa latenza.
- Le applicazioni tipiche includono telemetria, monitoraggio di rete, osservabilità, analisi di log e sistemi distribuiti.
- Nei contesti distribuiti non basta una buona stima locale: serve anche poter **combinare correttamente** sketch prodotti su nodi diversi.

Punto chiave

Il lavoro non riguarda solo quanto bene uno sketch stimi F_0 , ma come si comporta il **merge** in situazioni eterogenee o non ottimali.

Dal conteggio esatto allo sketch

Conteggio esatto

$$S_t = \langle x_1, \dots, x_t \rangle, \quad V_t = \{x_j \mid 1 \leq j \leq t\}$$

$$V_i \leftarrow V_{i-1} \cup \{x_i\}, \quad |V_t|$$

Memoria $\Theta(|V_t|) = \Theta(F_0(t))$: cresce con il numero di distinti osservati.

Sketch

$$S_t = \langle x_1, \dots, x_t \rangle, \quad M_0 = \text{sketch vuota}$$

$$M_i \leftarrow \text{Update}(M_{i-1}, x_i)$$

$$\widehat{F}_0(t) \leftarrow \text{Query}(M_t)$$

Si mantiene uno stato compatto e si restituisce una stima di $F_0(t)$.

- L'hash trasforma gli elementi in sequenze pseudo-casuali e la stima ne osserva i pattern nei bit dello sketch.
- Il compromesso fondamentale è tra memoria, costo di aggiornamento e accuratezza della stima.
- In un contesto distribuito c'è un ulteriore requisito: il merge degli sketch locali.

Caso distribuito e domanda di ricerca

$$S_1 \longrightarrow K_1 \quad S_2 \longrightarrow K_2 \quad S_3 \longrightarrow K_3$$

Per un algoritmo fissato $\mathcal{A}$, $\oplus_{\mathcal{A}}$ denota il merge su sketch compatibili; K_{serial} è lo sketch ottenuto processando $S_1 \parallel S_2 \parallel S_3$, con $\parallel$ concatenazione dei flussi.

$$\text{Query}(K_1 \oplus_{\mathcal{A}} K_2 \oplus_{\mathcal{A}} K_3) = \text{Query}(K_{\text{serial}})$$

- Ogni nodo mantiene uno sketch locale della propria partizione del flusso o della propria partizione temporale.
- In un sistema possono cambiare algoritmo, funzione di hash, seed e precisione dello sketch.
- Il punto è capire quando il merge coincide ancora col caso seriale.

Domanda di ricerca

Quando il merge è semanticamente corretto, quando è recuperabile e quando invece deve essere rifiutato?

Tesi del lavoro

Negli sketch count-distinct distribuiti, hash, seed e parametri non sono dettagli di implementazione: fanno parte della **semantica** dello sketch e quindi della correttezza del merge.

- Implementazione uniforme di Probabilistic Counting, LogLog, HyperLogLog e HyperLogLog++.
- Framework sperimentale che separa algoritmi, hashing, dataset, metriche e risultati.
- Classificazione operativa dei casi di merge in *valid*, *recoverable* e *invalid*.
- Valutazione empirica di casi eterogenei cercati, con HLL++ come riferimento principale.

Contenuto della tesi

Non viene proposto un nuovo stimatore teorico: il contributo è uno studio sistematico del comportamento degli sketch e del merge su un dataset sintetico con proprietà controllate.

$$S = \langle x_1, x_2, \dots, x_s \rangle, \quad x_i \in \mathcal{U}$$

$$f(a) = |\{i \mid x_i = a\}| \quad F_0 = |\{a \in \mathcal{U} \mid f(a) > 0\}|$$

- S è un flusso ordinato di elementi osservati.
- $f(a)$ conta quante volte compare la chiave a .
- F_0 è il numero di elementi distinti nel flusso.
- Nel lavoro si considera il modello *insertion-only*.

Algoritmo di streaming

$$S_i = \langle x_1, \dots, x_i \rangle, \quad M_0 = \text{stato vuoto}$$

$$M_i \leftarrow \text{Update}(M_{i-1}, x_i), \quad \widehat{F}_0(S_i) \leftarrow \text{Query}(M_i)$$

- Lo stato M_i deve essere piccolo rispetto al prefisso processato.
- L'aggiornamento deve essere veloce, perché avviene per ogni elemento.
- L'accuratezza è lo scostamento tra $\widehat{F}_0(S_i)$ e $F_0(S_i)$.
- L'obiettivo è di scambiare la quantità di memoria per una stima controllata.

Stima

Una stima (ε, δ) -approssimata richiede $\Pr(|\widehat{F}_0 - F_0| \leq \varepsilon F_0) \geq 1 - \delta$.

Linea evolutiva degli algoritmi di sketch

Metodo	Stato mantenuto	Miglioramento introdotto
Probabilistic Counting	Una bitmap	-
PCSA	Più bitmap virtuali	Mediazione su sottostrutture
LogLog	Registri	Massimi di rango
HyperLogLog	Registri	Media armonica e correzioni
HyperLogLog++	Registri con strutture sparse/dense	Bias correction e gestione pratica dei regimi piccoli

Struttura di Probabilistic Counting

Si usa una bitmap $B[1], \dots, B[L] \in \{0, 1\}$ e una funzione di hash uniforme $h : \mathcal{U} \rightarrow \{0, 1\}^L$. Per $y = h(x)$, si definiscono

$$\rho(y) = \min\{1 + \nu_2(y), L\}, \quad R(B) = \min(\{r \geq 1 : B[r] = 0\} \cup \{L + 1\})$$

Aggiornamento

$$r \leftarrow \rho(h(x)), \quad B[r] \leftarrow 1$$

La bitmap registra l'evento raro osservato sull'hash tramite la posizione del bit attivato.

La struttura è estremamente compatta, ma una sola bitmap produce varianza elevata. PCSA nasce proprio per ridurre questa instabilità.

Stima

$$\widehat{F}_0 \approx \frac{2^{R(B)}}{\phi}$$

$R(B)$ è la posizione del primo zero e ϕ è una costante di calibrazione empirica.

Struttura comune e stima LogLog

Precisione k : si usano $m = 2^k$ registri $M[0], \dots, M[m-1]$. Con un hash di L bit:

$$h(x) = \underbrace{j}_{k \text{ bit}} \parallel \underbrace{w}_{L-k \text{ bit}}, \quad r = \text{bin}(j), \quad \rho(w) = 1 + \text{zeri iniziali in } w$$

Aggiornamento

$$M[r] \leftarrow \max\{M[r], \rho(w)\}$$

Ogni registro memorizza il massimo rango osservato sugli elementi assegnati a quel registro.

Stima LogLog

$$A = \frac{1}{m} \sum_{r=0}^{m-1} M[r], \quad \widehat{F}_0 = \alpha_m \cdot m \cdot 2^A$$

LogLog usa la media dei ranghi e risale alla cardinalità su scala esponenziale.

LogLog, HyperLogLog e HyperLogLog++ condividono stato e aggiornamento. Le slide successive cambiano solo il modo in cui questo stato viene interrogato.

HyperLogLog: media armonica e regimi

Idea

HyperLogLog mantiene identici registri e aggiornamento di LogLog, ma sostituisce la query con una media armonica sui registri.

Stima grezza

$$Z = \sum_{r=0}^{m-1} 2^{-M[r]}, \quad E = \alpha_m \frac{m^2}{Z}$$

La media armonica di $2^{-M[r]}$ attenua il peso dei registri estremi.

Per E vicino a 2^L , HLL applica inoltre una correzione di saturazione.

Regimi principali

Se $V_0 = |\{r : M[r] = 0\}|$, allora

$$\widehat{F}_0 = \begin{cases} m \log(m/V_0), & \text{se } E \leq \frac{5}{2}m \text{ e } V_0 > 0 \\ E, & \text{nel regime centrale} \end{cases}$$

HyperLogLog++: bias correction, threshold e formato

Idea

HyperLogLog++ mantiene il nucleo di HLL, ma aggiunge correzione del bias, rappresentazione sparsa/densa e una soglia empirica per la scelta finale.

Bias correction

Indicando con E la stima grezza di HLL,

$$E_{\text{corr}} = \begin{cases} E - \beta(E, k), & \text{se } E \leq 5m \\ E, & \text{altrimenti} \end{cases}$$

$\beta(E, k)$ è una correzione empirica tabulata per la precisione k .

Se $V_0 > 0$, si pone $H = m \log(m/V_0)$. HLL++ restituisce H se $H \leq \text{Threshold}(k)$, altrimenti E_{corr} .

Differenze strutturali

- funzione di hash a 64 bit;
- formato sparso per cardinalità piccole e denso oltre soglia;
- nella codifica sparsa può comparire una precisione k' con $k \leq k' \leq 64$.

Merge e compatibilità semantica

Obiettivo del merge

Il merge corretto richiede

$$\text{Query}(K_1 \oplus_{\mathcal{A}} K_2) = \text{Query}(K_{\text{serial}})$$

Famiglia bitmap

Probabilistic Counting e PCSA.

$$B = B_1 \vee B_2$$

Merge bit a bit dello stato.

Famiglia a registri

LogLog, HLL e HLL++.

$$\forall j \in \{0, \dots, m-1\}, \quad M[j] = \max\{M_1[j], M_2[j]\}$$

Merge componente per componente.

Compatibilità richiesta

L'operazione $\oplus_{\mathcal{A}}$ è corretta solo con **algoritmo**, **hash/seed** e **parametri strutturali** invariati.

Classificazione dei casi di merge

Il controllo di compatibilità produce tre esiti: merge diretto, merge dopo normalizzazione, oppure rifiuto del merge.

valid

Merge diretto.
Stesso algoritmo, stessa hash,
stesso seed, stessi parametri.

recoverable

Merge corretto dopo
normalizzazione.
HLL++ con precisioni diverse e
stessa semantica hash.

invalid

Merge da rifiutare.
Hash family o seed diversi.

Strategie operative

valid $\rightarrow$ direct, recoverable $\rightarrow$ reduce_then_merge, invalid $\rightarrow$ reject.
unsafe_naive_merge è usato solo come controllo negativo.

Infrastruttura sperimentale

Idea

Il framework separa algoritmi, hashing, dataset e valutazione, così da isolare gli effetti del merge.

Algoritmi

API comune per process, count, merge, reset.
Implementazioni: PC, LogLog, HLL, HLL++ e algoritmo naive.

Hash e dataset

Funzioni di hash separate dal livello dello sketch.
Seed, parametri e metadati sono tracciati esplicitamente.


Valutazione

Modalità streaming, merge omogeneo e merge eterogeneo.
Metriche e risultati sono serializzati in CSV riproducibili.

Scelta progettuale

Il framework rende osservabile la compatibilità semantica del merge sotto condizioni riproducibili.

Architettura del sistema



Dataset sintetico: protocollo di generazione

Parametri

Per ogni dataset: $n = 10^7$ elementi per partizione, $p = 50$, seed globale = 21041998,

$$\rho = \frac{n}{d} \in \{100, 50, 20, 10, 5, 2, 1\}, \quad n \bmod d = 0.$$

Costruzione di una partizione

- 1 seed locale deterministico dal seed globale e dall'indice di partizione;
- 2 estrazione di d interi distinti;
- 3 una nuova prima occorrenza all'inizio di ogni blocco di lunghezza ρ ;
- 4 completamento del blocco campionando tra gli identificatori già visti.

Proprietà indotta

Ogni blocco introduce esattamente un nuovo elemento distinto. Quindi, al bordo del j -esimo blocco,

$$F_0(j \cdot \rho) = j.$$

Il protocollo separa in modo controllato la crescita di $F_0(t)$ dal numero medio di ripetizioni.

Dataset sintetico: formato e verità di prefisso

Formato binario

Ogni file ha nome

`dataset_n_{n}_d_{d}_p_{p}_s_{seed}.bin`

e contiene:

- header con SATPDBN2, versione, n , d , p , seed;
- tabella delle partizioni con offset e dimensioni compresse;
- payload dei valori e truth bitset compressi separatamente con zlib.

Uso nel framework

PartitionReader carica una partizione alla volta, quindi il costo in memoria è proporzionale alla partizione corrente e non all'intero dataset.

Truth bitset

Il bit $b_t = 1$ se la posizione t è una prima occorrenza. Perciò

$$F_0(t) = \sum_{i=1}^t b_i.$$


Dataset sintetico: validazione

Verifiche

- header e partizioni coerenti;
- in ogni partizione, $\sum_t b_t = d$;
- una prima occorrenza per blocco;
- determinismo rispetto ai worker.

$$\rho_t = \frac{t}{F_0(t)}$$

Ai bordi $t = j\rho$, vale $\rho_t = \rho$.



Protocollo sperimentale: organizzazione

Idea

Il protocollo separa tre domande: accuratezza in streaming, merge omogeneo e casi nel merge eterogeneo.

Modalità

- streaming;
- merge;
- merge_heterogeneous.

Tre flussi di valutazione del framework.

Unità di esecuzione

Il dataset ha $p = 50$ partizioni. In streaming ogni partizione è un esperimento; nel merge le coppie sono

$(0, 1), (2, 3), \dots, (48, 49)$.

File di risultati

Risultati salvati in

```
results/<namespace>/  
<mode>/.../results_*.csv
```

con metadati su dataset, hash, parametri e strategia di merge.

Metriche principali

Streaming: media, deviazione standard, bias, RMSE e MRE finale. Merge: stima di merge, stima seriale, unione esatta e delta rispetto al riferimento.

Esperimenti in modalità di flusso: configurazione

Configurazione

Dataset `prefix_constant_rho` con $n = 10^7$, $p = 50$, `seed = 21041998` e

$$\rho \in \{1, 10, 100\}.$$

Griglie: HLL++ con $k \in \{8, 10, 12, 14, 16, 18\}$; HLL e LogLog con $k \in \{4, 6, 8, 10, 12, 14, 16\}$; PC con $L \in \{4, 8, 12, 16, 20, 24, 28, 31\}$.

Struttura dell'analisi

Non si osservano tutti i 10^7 elementi del flusso, ma 200 punti di controllo fissati in anticipo.

Nel caso $n = 10^7$, il pianificatore:

- distribuisce circa un terzo dei checkpoint in modo lineare nel primo 1% del flusso;
- distribuisce i restanti checkpoint fino a n con passo crescente;
- include sempre $t = 1$ e $t = n$.

Lettura intuitiva

In pratica si fanno 200 “istantanee” del flusso: fitte all’inizio, dove la stima cambia più rapidamente, e poi via via più rade.

A ciascun checkpoint si confrontano $F_0(t)$ e $\widehat{F}_0(t)$; sulle 50 partizioni si aggregano poi media e dispersione.

Esperimenti in modalità di flusso: lettura dei risultati

Idea

Gli stessi esperimenti vengono letti rispetto alla cardinalità reale del prefisso e rispetto al rapporto medio di ripetizione.

Caso A

Si osserva $\widehat{F}_0(t)$ in funzione di $F_0(t)$ a ρ fissato. Questa vista mostra come cambiano bias e dispersione al crescere dei distinti reali nel prefisso.

Caso B

Si fissano sette valori target

$$F_0^* \in \{10^3, 2 \cdot 10^3, 5 \cdot 10^3, 10^4, 2 \cdot 10^4, 5 \cdot 10^4, 10^5\}$$

e si legge la stima in funzione di

$$\rho_t = \frac{t}{F_0(t)}.$$

Sintesi comparativa

Confronto finale tramite errore relativo medio ai punti finali del flusso.

Esperimenti di merge HLL++: struttura

Procedura comune

Le partizioni sono accoppiate come $(0, 1), (2, 3), \dots, (48, 49)$. Per ogni coppia si costruiscono due sketch locali e uno sketch seriale sulla stessa unione dei dati, poi si confronta il merge con il riferimento.

Controllo omogeneo

$$\rho \in \{1, 10, 100\}, \quad k \in \{10, 14, 18\}$$

Quattro funzioni di hash, stessa semantica sui due lati.

Strategia osservata: `direct`.

Totale: 36 configurazioni, 900 coppie.

Quantità registrate

Per ogni coppia si salvano unione esatta, stima di merge, stima seriale ed errori assoluti e relativi rispetto al riferimento.

Nel caso `valid`, il controllo atteso è

$$\Delta_{abs} = 0, \quad \Delta_{rel} = 0.$$

Esperimenti di merge HLL++: casi eterogenei

Caso invalid: hash mismatch

Precisione fissata a $k = 14$. Scenari osservati: controllo omogeneo locale, seed mismatch e family mismatch, anche in versione rev.

Strategie: `reject`, `unsafe_naive_merge`.

Totale: 1800 righe, 72 file CSV.

Caso recoverable: precision mismatch

Hash fissata a xxhash64 con seed comune.

Coppie:

$(10, 14), (10, 18), (14, 18)$

e inverse.

Strategie: `reject`, `unsafe_naive_merge`, `reduce_then_merge`.

Totale: 1350 righe, 54 file CSV.

Riferimenti di confronto

`reject` registra esplicitamente l'incompatibilità; `unsafe_naive_merge` è il controllo negativo; nel caso `recoverable`, `reduce_then_merge` usa come riferimento omogeneo la precisione minima $\min(k_{\text{left}}, k_{\text{right}})$.

Validazione della catena sperimentale

Test sugli algoritmi

- accuratezza di base e dominio dei parametri;
- merge seriale, commutatività e idempotenza per PC, LogLog, HLL e HLL++;
- eccezioni sui mismatch parametrici non ammessi;
- per HLL++: merge sparse+normal, riduzione corretta di precisione e controesempio naive.

Test del framework

- in streaming, uso corretto di $F_0(t)$ del dataset;
- planner di 200 checkpoint: copertura del flusso e rispetto della configurazione;
- serializzazione coerente dei CSV di streaming, merge e merge eterogeneo;
- casi valid, invalid e recoverable con le relative strategie.


Test del dataset e dell'orchestrazione

Il generatore verifica header binario, tabella delle partizioni, truth bitset, relazione $\sum_t b_t = d$, una sola prima occorrenza per blocco e determinismo del file anche variando i worker. Gli script di orchestrazione fissano in modo deterministico griglie parametriche, hash, naming dei risultati e percorsi dei CSV.

Risultati streaming: sintesi ai punti finali

Idea

L'errore relativo medio ai punti finali osservati sintetizza la qualità della stima nelle due viste già introdotte: in funzione di $F_0(t)$ e di $\rho_t = t/F_0(t)$.



Osservazioni


- sulla vista in $F_0(t)$, HLL e HLL++ sono quasi sovrapposti: errore medio circa 0.00618;
- sulla vista in ρ_t , HLL++ è il migliore: $3.95 \cdot 10^{-4}$, contro $2.08 \cdot 10^{-3}$ di HLL;
- LogLog è più sensibile alla vista sperimentale;
- Probabilistic Counting resta nettamente separato dagli altri;
- HLL++ è l'unico metodo che resta primo in entrambe le viste.

Risultati streaming: analisi del parametro di precisione

Configurazione

Per isolare l'effetto del parametro interno si fissano dataset, seed e hash (splitmix64, seed = 21041998) e si varia solo la precisione dell'algoritmo per $\rho \in \{1, 10, 100\}$.

Sweep di precisione in streaming: heatmap dell'errore finale



Miglior parametro osservato

- HLL++: $k = 18$ per tutti i valori di ρ ;
- HLL: $k = 16$ in media, ma con $\rho = 1$ basta $k = 10$;
- LogLog: $k = 14$ in media, con preferenza per $k = 16$ a $\rho = 10$;
- PC: $L = 20$ in media, con $L = 16$ quando $\rho = 100$;
- solo HLL++ migliora in modo davvero sistematico.

Merge omogeneo: controllo del caso valid

Perché serve

Prima di studiare i mismatch bisogna verificare che, in condizioni pienamente compatibili, merge e processamento seriale coincidano davvero.

Configurazione

HyperLogLog++ con

$$\rho \in \{1, 10, 100\}, \quad k \in \{10, 14, 18\}$$

e quattro funzioni di hash. Totale osservato: 36 configurazioni e 900 coppie di merge.

Risultato osservato

$$\Delta_{abs} = 0, \quad \Delta_{rel} = 0$$


ρ	d	Coppie	Delta $\neq 0$	Max Δ_{rel}
1	10^7	300	0	0
10	10^6	300	0	0
100	10^5	300	0	0

In tutte le 900 coppie osservate, merge e riferimento seriale coincidono.

Hash mismatch: caso invalid

Configurazione

Precisione fissata a $k = 14$. Si osservano seed mismatch e family mismatch, con controllo omogeneo locale e scenari invertiti rev. Le strategie usate sono reject e unsafe_naive_merge.



Osservazioni

- controllo omogeneo locale: errore medio = 0.006233;
- merge forzato nei casi invalid: errore medio tra 0.342374 e 0.352802;
- errore massimo osservato: 1.009634, nel regime $\rho = 1$;
- invertire i lati non ripara il problema semantico;
- operativamente il caso va rifiutato: reject.


Precision mismatch: caso recoverable

Configurazione

Hash xxhash64, seed comune e coppie di precisione

(10, 14), (10, 18), (14, 18)

con versioni inverse. Si confrontano reject, unsafe_naive_merge e reduce_then_merge.



Strategie a confronto


Strategia	$\bar{\epsilon}_{merge}$
reject	—
unsafe_naive_merge	0.363882
reduce_then_merge	0.016651

La riduzione alla precisione minima comune riporta il merge sul riferimento seriale e sul corrispondente riferimento omogeneo. Il merge forzato raggiunge invece massimo 1.061378 e degrado medio 32.37.

Sintesi trasversale del merge HLL++

Idea

Letti insieme, i tre casi osservati chiariscono il significato operativo della classificazione valid/recoverable/invalid.



Conclusione

valid $\Rightarrow$ direct

invalid $\Rightarrow$ reject

recoverable $\Rightarrow$ reduce_then_merge

Conclusioni: cosa mostrano i risultati

Stima locale

- Nel dominio osservato, HLL++ è il metodo più stabile.
- HyperLogLog resta il metodo più vicino per comportamento, ma meno regolare.
- LogLog e soprattutto PC dipendono di più dal regime sperimentale e dal parametro scelto.

Merge distribuito

- il caso omogeneo coincide con il riferimento seriale;
- l'hash mismatch rompe la semantica comune del merge;
- il precision mismatch non è diretto, ma resta recuperabile con normalizzazione.

Tesi centrale

Negli sketch count-distinct distribuiti, algoritmo, hash, seed e parametri fanno parte della semantica dello sketch: il merge è corretto solo entro questa semantica comune.

Conclusioni: contributi del lavoro

Software

Implementazione uniforme di più algoritmi count-distinct, con interfaccia comune per aggiornamento, stima, merge e reset.

Metodo

Framework riproducibile che separa dataset, hash, algoritmi, metriche e serializzazione e supporta streaming, merge omogeneo e merge eterogeneo.

Risultato principale

Distinzione operativa tra casi `valid`, `recoverable` e `invalid`, con evidenza sperimentale sulle condizioni del merge.

Contributo complessivo

Il lavoro non si limita a confrontare algoritmi: esplicita quando il merge distribuito sia semanticamente corretto, quando vada rifiutato e quando richieda una trasformazione preliminare definita.

Idea

I risultati chiariscono bene il problema semantico di base, ma non esauriscono ancora la varietà dei flussi reali e delle topologie distribuite.

Dataset

La valutazione usa soprattutto un dataset sintetico controllato, utile per isolare i fenomeni ma non sufficiente da solo a rappresentare tutti i carichi reali.

Topologia

Lo studio del merge si concentra su casi pairwise, che chiariscono la semantica del problema ma non coprono catene o alberi di aggregazione più ampi.

Assi osservati

I casi eterogenei osservati sono due assi mirati (`hash mismatch`, `precision mismatch`) e il merge è sviluppato soprattutto su HLL++ come riferimento principale.

Sviluppi futuri

Dati reali

Portare il framework su dataset reali o su sorgenti di flusso come Apache Kafka, per osservare gli algoritmi fuori dal solo contesto sintetico.

Topologie e costi

Studiare topologie di merge più ampie e il punto ottimale in cui ridurre alla precisione minima, misurando anche costo di normalizzazione e merge.

Nuovi sketch

Estendere il framework ad algoritmi count-distinct più recenti (per esempio UltraLogLog) e, più avanti, ad altre famiglie di sketch.

Stesso principio

Le estensioni future hanno senso soprattutto lungo assi di eterogeneità la cui interpretazione semantica sia chiara, come in questo lavoro.

Conclusione

Negli sketch count-distinct distribuiti, hash, seed e parametri non sono dettagli di implementazione: fanno parte della semantica dello sketch.

Conseguenza operativa

`valid` $\Rightarrow$ `direct` `recoverable` $\Rightarrow$ `reduce_then_merge` `invalid` $\Rightarrow$ `reject`

Grazie per l'attenzione

Domande?