

Stima della cardinalità nei flussi di dati distribuiti: merge e compatibilità semantica degli algoritmi di sketch

Seminario di tesi magistrale

Daniele Ferroli

Università degli Studi di Udine

A.A. 2024–2025

- 1 Motivazione e domanda di ricerca
- 2 Sketch count-distinct
- 3 Merge e compatibilità semantica
- 4 Infrastruttura sperimentale
- 5 Risultati sugli algoritmi
- 6 Risultati sul merge distribuito
- 7 Conclusioni

Motivazione e domanda di ricerca

- Il problema riguarda la stima degli **elementi distinti** che compaiono in un flusso di dati continuo.
- Il conteggio esatto diventa rapidamente costoso in memoria e tempo quando il numero di elementi distinti cresce e la risposta deve essere aggiornata con bassa latenza.
- Le applicazioni tipiche includono telemetria, monitoraggio di rete, osservabilità, analisi di log e sistemi distribuiti.
- Nei contesti distribuiti non basta una buona stima locale: serve anche poter **combinare correttamente** i risultati prodotti su nodi diversi.

Punto chiave

Il lavoro non riguarda solo quanto bene gli algoritmi stimino gli elementi distinti, ma come si comporta il **merge** in situazioni eterogenee o non ottimali.

Dal conteggio esatto allo sketch

Conteggio esatto

$$\begin{aligned} S_t &= \langle x_1, \dots, x_t \rangle, & V_t &= \{x_j \mid 1 \leq j \leq t\} \\ V_i &\leftarrow V_{i-1} \cup \{x_i\}, & 1 \leq i \leq t, \\ |V_t| &= F_0(t) \end{aligned}$$

Memoria $\Theta(|V_t|) = \Theta(F_0(t))$: cresce con il numero di distinti osservati.

Sketch

$$\begin{aligned} S_t &= \langle x_1, \dots, x_t \rangle, & M_0 &= \text{sketch vuoto} \\ M_i &\leftarrow \text{Update}(M_{i-1}, x_i), & 1 \leq i \leq t, \\ \widehat{F}_0(t) &\leftarrow \text{Query}(M_t) \end{aligned}$$

Si mantiene uno stato compatto e si restituisce una stima di $F_0(t)$.

Complessità dello sketch

Per una $(1 \pm \varepsilon)$ -stima con probabilità $1 - \delta$:

$$\text{space}(M_t) = O(\varepsilon^{-2} \log \log n + \log n), \quad n = |\mathcal{U}|.$$

Update per elemento: $O(1)$ operazioni sullo stato. Il compromesso resta tra memoria, costo di aggiornamento e accuratezza; nel caso distribuito si aggiunge il merge degli sketch locali.

$$S_1 \longrightarrow K_1 \quad S_2 \longrightarrow K_2$$

Per un algoritmo fissato $\mathcal{A}$, $\oplus_{\mathcal{A}}$ denota il merge su sketch compatibili; K_{serial} è lo sketch ottenuto processando $S_1 \parallel S_2$, con $\parallel$ concatenazione dei flussi.

$$\text{Query}(K_1 \oplus_{\mathcal{A}} K_2) = \text{Query}(K_{\text{serial}})$$

- Ogni nodo mantiene uno sketch locale della propria partizione del flusso o della propria partizione temporale.
- In un sistema possono cambiare algoritmo, funzione di hash, seed e precisione dello sketch.
- Il punto è capire quando il merge coincide ancora col caso seriale.

Domanda di ricerca

Quando il merge è semanticamente corretto, quando è recuperabile e quando invece deve essere rifiutato?

Risultato principale

Negli sketch count-distinct distribuiti, hash, seed e parametri non sono dettagli di implementazione: fanno parte della **semantica** dello sketch e quindi della correttezza del merge.

Contributi:

- Implementazione degli algoritmi Probabilistic Counting, LogLog, HyperLogLog e HyperLogLog++.
- Framework sperimentale che separa algoritmi, hashing, dataset, metriche e risultati.
- Classificazione operativa dei casi di merge in *valid*, *recoverable* e *invalid*.
- Valutazione empirica di casi eterogenei cercati, con HLL++ come riferimento principale.

Non viene proposto un **nuovo stimatore teorico**: il contributo è uno **studio sistematico** del comportamento degli sketch e del merge su un dataset sintetico con proprietà controllate.

Sketch count-distinct

$$S = \langle x_1, x_2, \dots, x_s \rangle, \quad x_i \in \mathcal{U}$$

$$f(a) = |\{i \mid x_i = a\}| \quad F_0 = |\{a \in \mathcal{U} \mid f(a) > 0\}|$$

- S è un flusso ordinato di elementi osservati.
- $f(a)$ conta quante volte compare la chiave a .
- F_0 è il numero di elementi distinti nel flusso.
- Nel lavoro si considera il modello *insertion-only*.

Definizione

Un algoritmo per flussi di dati elabora $S = \langle x_1, \dots, x_s \rangle$ in un solo passaggio, mantiene uno stato interno M_i di dimensione limitata e aggiorna tale stato dopo ogni elemento osservato. In qualunque momento può restituire una risposta interrogando lo stato.

$$S_i = \langle x_1, \dots, x_i \rangle,$$

$$M_0 = \text{stato vuoto}$$

$$M_i \leftarrow \text{Update}(M_{i-1}, x_i),$$

$$\widehat{F}_0(S_i) \leftarrow \text{Query}(M_i)$$

- M_i deve restare piccolo rispetto al prefisso processato.
- Update deve essere veloce, perché avviene per ogni elemento.
- La qualità si misura confrontando $\widehat{F}_0(S_i)$ con $F_0(S_i)$.

Stima

Una stima (ε, δ) -approssimata richiede

$$\Pr\left(|\widehat{F}_0(S_i) - F_0(S_i)| \leq \varepsilon F_0(S_i)\right) \geq 1 - \delta.$$

Famiglie implementate e valutate

Nel lavoro sperimentale vengono considerati algoritmi probabilistici per la stima di F_0 , tutti basati sull'uso di funzioni di hash e su uno stato compatto aggiornato elemento per elemento.

- **Probabilistic Counting**: mantiene una bitmap e stima la cardinalità a partire dalla posizione dei bit osservati.
- **LogLog**: usa registri che memorizzano massimi di rango prodotti dall'hash.
- **HyperLogLog**: mantiene la struttura a registri, ma cambia lo stimatore usando la media armonica.
- **HyperLogLog++**: variante pratica di HyperLogLog con rappresentazione sparsa/densa, correzioni del bias e gestione dei regimi piccoli.

Struttura della famiglia di algoritmi LogLog

Precisione k : si usano $m = 2^k$ registri $M[0], \dots, M[m-1]$.

Con un hash di L^* bit:

$$h(x) = \underbrace{j}_{k \text{ bit}} \parallel \underbrace{w}_{L-k \text{ bit}}, \quad r = \text{bin}(j), \quad \rho(w) = 1 + \text{zeri iniziali}^{**} \text{ in } w$$

* = 32 bit in genere

** = leggendo i bit da sinistra a destra

Aggiornamento

$$M[r] \leftarrow \max\{M[r], \rho(w)\}$$

Ogni registro memorizza il massimo rango osservato sugli elementi assegnati a quel registro.

Stima LogLog

$$A = \frac{1}{m} \sum_{r=0}^{m-1} M[r], \quad \widehat{F}_0 = \alpha_m \cdot m \cdot 2^A$$

LogLog usa la media dei ranghi e risale alla cardinalità su scala esponenziale.

La famiglia condivide la struttura a registri. Nei miglioramenti successivi viene modificata la funzione di stima e vengono applicate correzioni sulla stima in maniera empirica.

```
Choose the precision  $k$  and set  $m = 2^k$   
Initialize the registers  $M[0], \dots, M[m-1] \leftarrow 0$   
for each element  $x$  in the stream do  
     $y \leftarrow h(x)$   
     $j \leftarrow \text{Prefix}_k(y)$   
     $w \leftarrow \text{Suffix}_{L-k}(y)$   
     $M[j] \leftarrow \max\{M[j], \rho(w)\}$   
end for  
 $A \leftarrow \frac{1}{m} \sum_{j=0}^{m-1} M[j]$   
return  $\widehat{F}_0 \leftarrow \alpha_m \cdot m \cdot 2^A$ 
```

LogLog: esempio operativo

Consideriamo $k = 2$, quindi $m = 4$ registri, e hash su $L = 8$ bit. I primi due bit selezionano il registro j ; i restanti sei bit formano il suffisso w , da cui si calcola $\rho(w)$.

Passo	x	$y = h(x)$	j	w	$\rho(w)$	Stato registri	$\widehat{F}_0$
1	a	10010100_2	2	010100_2	2	$(0, 0, 2, 0)$	≈ 2.25
2	b	10111000_2	2	111000_2	1	$(0, 0, 2, 0)$	≈ 2.25
3	c	01001100_2	1	001100_2	3	$(0, 3, 2, 0)$	≈ 3.78
4	d	11001000_2	3	001000_2	3	$(0, 3, 2, 3)$	≈ 6.352
5	e	10000100_2	2	000100_2	4	$(0, 3, 4, 3)$	≈ 8.98

Merge e compatibilità semantica

Il merge corretto richiede

$$\text{Query}(K_1 \oplus_{\mathcal{A}} K_2) = \text{Query}(K_{\text{serial}})$$

Famiglia a registri

LogLog, HLL e HLL++.

$$\forall j \in \{0, \dots, m-1\}, \quad M[j] = \max\{M_1[j], M_2[j]\}$$

Merge componente per componente.

L'operazione $\oplus_{\mathcal{A}}$ è corretta solo con **algoritmo**, **hash/seed** e **parametri strutturali** invariati.

Classificazione dei casi di merge

Il controllo di compatibilità produce tre esiti: merge diretto, merge dopo normalizzazione, oppure rifiuto del merge.

valid

Merge diretto.
Stesso algoritmo, stessa hash,
stesso seed, stessi parametri.

recoverable

Merge corretto dopo
normalizzazione.
HLL++ con precisioni diverse e
stessa semantica hash.

invalid

Merge da rifiutare.
Funzioni di hash o seed diversi.

Strategie utilizzate

valid $\rightarrow$ direct, recoverable $\rightarrow$ reduce_then_merge, invalid $\rightarrow$ reject.
unsafe_naive_merge è usato solo come controllo negativo.

Infrastruttura sperimentale

Infrastruttura sperimentale

Il framework separa algoritmi, hashing, dataset e valutazione, così da isolare gli effetti del merge.

Algoritmi

API comune per process, count, merge, reset.
Implementazioni: PC, LogLog, HLL, HLL++ e algoritmo naive.

Hash e dataset

Funzioni di hash separate dal livello dello sketch.
Seed, parametri e metadati sono tracciati esplicitamente.


Valutazione

Modalità streaming, merge omogeneo e merge eterogeneo.
Metriche e risultati sono serializzati in CSV riproducibili.

Scelta progettuale

Il framework rende osservabile la compatibilità semantica del merge sotto condizioni riproducibili.

Architettura del sistema



Dataset sintetico: protocollo di generazione

Parametri

Per ogni dataset: $n = 10^7$ elementi per partizione, $p = 50$ partizioni, d elementi distinti, seed globale = 21041998,

$$\rho = \frac{n}{d} \in \{100, 50, 20, 10, 5, 2, 1\}, \quad n \bmod d = 0.$$

Costruzione di una partizione

- ① seed locale deterministico dal seed globale e dall'indice di partizione;
- ② estrazione di d interi distinti;
- ③ una nuova prima occorrenza all'inizio di ogni blocco di lunghezza ρ ;
- ④ completamento del blocco campionando tra gli identificatori già visti.

Proprietà indotta

Ogni blocco introduce esattamente un nuovo elemento distinto. Quindi, al bordo del j -esimo blocco,

$$F_0(j \cdot \rho) = j.$$

Il protocollo separa in modo controllato la crescita di $F_0(t)$ dal numero medio di ripetizioni.

Dataset sintetico: esempio di partizione

Esempio piccolo

Supponiamo $n = 12$, $d = 4$ e quindi $\rho = n/d = 3$. La partizione è divisa in quattro blocchi di lunghezza 3: all'inizio di ogni blocco compare una nuova prima occorrenza.

t	1	2	3	4	5	6	7	8	9	10	11	12
blocco	1			2			3			4		
x_t	a	a	a	b	a	b	c	a	c	d	b	c
b_t	1	0	0	1	0	0	1	0	0	1	0	0
$F_0(t)$	1	1	1	2	2	2	3	3	3	4	4	4

Cosa viene memorizzato

Il dataset contiene la sequenza dei valori x_t e un bitset di verità: $b_t = 1$ esattamente nelle posizioni in cui compare un nuovo distinto.

Verità di prefisso

La cardinalità reale del prefisso si ricostruisce sommando il bitset:

$$F_0(t) = \sum_{i=1}^t b_i.$$

Risultati sugli algoritmi

Protocollo sperimentale: organizzazione

Il protocollo segue la validazione del contesto, gli esperimenti sugli algoritmi e il merge distribuito.

Streaming

Si osserva la stima lungo i prefissi del flusso, confrontando $\widehat{F}_0(t)$ con la cardinalità reale $F_0(t)$.

Precisione

Si mantiene fisso il contesto di esecuzione e si varia il parametro interno di ciascun algoritmo.

Merge

Si confrontano merge omogeneo e casi eterogenei, distinguendo tra `valid`, `invalid` e `recoverable`.

Metriche principali

Streaming: media della stima, dispersione, bias ed errore relativo medio.

Merge: scostamento tra stima da merge e riferimento seriale.

Struttura comune per gli esperimenti in modalità streaming

Configurazione

Dataset `prefix_constant_rho` con $n = 10^7$, $p = 50$, `seed = 21041998` e

$$\rho \in \{1, 10, 100\}.$$

Griglie: HLL++ con $k \in \{8, 10, 12, 14, 16, 18\}$; HLL e LogLog con $k \in \{4, 6, 8, 10, 12, 14, 16\}$; Probabilistic Counting con $L \in \{4, 8, 12, 16, 20, 24, 28, 31\}$.

Struttura dell'analisi

Non si osservano tutti i 10^7 elementi del flusso, ma 200 punti di controllo fissati in anticipo.

Nel caso $n = 10^7$, il pianificatore:

- distribuisce circa un terzo dei checkpoint in modo lineare nel primo 1% del flusso;
- distribuisce i restanti checkpoint fino a n con passo crescente;
- include sempre $t = 1$ e $t = n$.

Lettura intuitiva

In pratica si fanno 200 “istantanee” del flusso: fitte all’inizio, dove la stima cambia più rapidamente, e poi via via più rade.

A ciascun checkpoint si confrontano $F_0(t)$ e $\widehat{F}_0(t)$; sulle 50 partizioni si aggregano poi media e dispersione.

Esperimenti sugli algoritmi: lettura dei risultati

Idea

L'analisi della robustezza separa due effetti: crescita della cardinalità reale del prefisso e rapporto medio di ripetizione.

Caso A

Si osserva $\widehat{F}_0(t)$ in funzione di $F_0(t)$ a ρ fissato.
Questa vista mostra come cambiano bias e dispersione al crescere degli distinti reali nel prefisso.

Caso B

Si fissano sette valori target

$$F_0^* \in \{10^3, 2 \cdot 10^3, 5 \cdot 10^3, 10^4, 2 \cdot 10^4, 5 \cdot 10^4, 10^5\}$$


e si legge la stima in funzione di

$$\rho_t = \frac{t}{F_0(t)}.$$

Il confronto finale usa l'errore relativo medio ai punti finali osservati.


Caso A: stima rispetto alla cardinalità reale

Type A - prelo_constant_rho (n=1000000, seed=21042908, scala lineare)



Scala lineare.


Type A - prelo_constant_rho (n=1000000, seed=21042908, scala log log)



Scala logaritmica.


Caso A: confronto HyperLogLog e HyperLogLog++

Type A (solo HLL/HLL++) - prefix_constant_rho (n=1000000, seed=23041993, scale linear)




Scala lineare.

Type A (solo HLL/HLL++) - prefix_constant_rho (n=1000000, seed=23041993, scale log-log)



Scala logaritmica.

Caso B: rapporto tra elementi processati e distinti




Scala lineare.



Scala logaritmica.

Caso B: confronto HyperLogLog e HyperLogLog++

Type B - HLL vs HLL++: stima $\pm$ stddev vs (partizioni medie effettive (lineare))




Scala lineare.

Type B - HLL vs HLL++: stima $\pm$ stddev vs (partizioni medie effettive (log-log))



Scala logaritmica.

L'errore relativo medio alla fine del flusso osservati sintetizza la qualità della stima nelle due viste già introdotte: in funzione di $F_0(t)$ e di $\rho_t = t/F_0(t)$.



Osservazioni


- sulla vista in $F_0(t)$, HLL e HLL++ sono quasi sovrapposti: errore medio circa 0.00618;
- sulla vista in ρ_t , HLL++ è il migliore: $3.95 \cdot 10^{-4}$, contro $2.08 \cdot 10^{-3}$ di HLL;
- LogLog è più sensibile alla vista sperimentale;
- Probabilistic Counting resta nettamente separato dagli altri;
- HLL++ è l'unico metodo che resta primo in entrambe le viste.

Risultati streaming: analisi del parametro di precisione

Configurazione

Per isolare l'effetto del parametro interno si fissano dataset, seed e hash (splitmix64, seed = 21041998) e si varia solo la precisione dell'algoritmo per $\rho \in \{1, 10, 100\}$.


Sweep di precisione in streaming: heatmap dell'errore finale




Miglior parametro osservato

- HLL++: $k = 18$ per tutti i valori di ρ ;
- HLL: $k = 16$ in media, ma con $\rho = 1$ basta $k = 10$;
- LogLog: $k = 14$ in media, con preferenza per $k = 16$ a $\rho = 10$;
- PC: $L = 20$ in media, con $L = 16$ quando $\rho = 100$;
- solo HLL++ migliora in modo davvero sistematico.

Parametro di precisione: confronto sui prefissi



Scala lineare.



Scala logaritmica.

Risultati sul merge distribuito

Esperimenti di merge HLL++: struttura

Procedura comune

Si costruiscono due sketch locali su partizioni distinte e uno sketch seriale sulla stessa unione dei dati; il merge viene poi confrontato con il riferimento seriale.

Controllo omogeneo

$$\rho \in \{1, 10, 100\}, \quad k \in \{10, 14, 18\}$$

Hash compatibile e stessa semantica sui due lati.

Strategia osservata: direct.

Quantità registrate

Per ogni confronto si salvano unione esatta, stima di merge, stima seriale ed errori assoluti e relativi rispetto al riferimento.

Nel caso valid, il controllo atteso è

$$\Delta_{abs} = 0, \quad \Delta_{rel} = 0.$$

Merge omogeneo: controllo del caso `valid`

Prima di studiare la degradazione data da un merge non ottimale bisogna verificare che, in condizioni pienamente compatibili, merge e processamento seriale coincidano davvero.

Configurazione

HyperLogLog++ con

$$\rho \in \{1, 10, 100\}, \quad k \in \{10, 14, 18\}$$

e hash compatibile sui due lati del merge.

Risultato osservato

$$\Delta_{abs} = 0, \quad \Delta_{rel} = 0$$

- per tutti i regimi ρ , il merge diretto riproduce il processamento seriale;
- non emerge alcuna differenza tra stima di merge e stima seriale;
- il caso `valid` diventa il riferimento per interpretare i mismatch successivi.

Esperimenti di merge HLL++: casi eterogenei

Caso invalid: hash mismatch

Precisione fissata a $k = 14$. Il controllo omogeneo locale viene confrontato con seed mismatch e family mismatch, anche invertendo i lati del merge.

Strategie: reject, unsafe_naive_merge.

Caso recoverable: precision mismatch

Hash fissata a xxhash64 con seed comune.

Si usano precisioni diverse, considerate in entrambi gli ordini di merge, mantenendo invariata la semantica dell'hash.

Strategie: reject, unsafe_naive_merge, reduce_then_merge.


Riferimenti di confronto

reject registra esplicitamente l'incompatibilità; unsafe_naive_merge è il controllo negativo; nel caso recoverable, reduce_then_merge usa come riferimento omogeneo la precisione minima $\min(k_{left}, k_{right})$.

Hash mismatch: caso invalid

Configurazione

Precisione fissata a $k = 14$. Si osservano seed mismatch e family mismatch, con controllo omogeneo locale e scenari invertiti rev. Le strategie usate sono reject e unsafe_naive_merge.




Osservazioni

- controllo omogeneo locale: errore medio = 0.006233;
- merge forzato nei casi invalid: errore medio tra 0.342374 e 0.352802;
- errore massimo osservato: 1.009634, nel regime $\rho = 1$;
- invertire i lati non ripara il problema semantico;
- operativamente il caso va rifiutato: reject.

Precision mismatch: caso recoverable

Configurazione

Hash xxhash64, seed comune e precisioni diverse tra i due sketch, considerate in entrambi gli ordini di merge. Si confrontano reject, unsafe_naive_merge e reduce_then_merge.



Strategie a confronto

Strategia	$\bar{\epsilon}_{merge}$
reject	—
unsafe_naive_merge	0.363882
reduce_then_merge	0.016651

La riduzione alla precisione minima comune riporta al merge sul riferimento seriale e sul corrispondente riferimento omogeneo. Il merge forzato raggiunge invece massimo 1.061378 e degrado medio 32.37.

Conclusioni

Conclusioni: cosa mostrano i risultati

Stima locale

- Nel dominio osservato, HLL++ è il metodo più stabile.
- HyperLogLog resta il metodo più vicino per comportamento, ma meno regolare.
- LogLog e soprattutto PC dipendono di più dal regime sperimentale e dal parametro scelto.

Merge distribuito

- il caso omogeneo coincide con il riferimento seriale;
- due funzioni di hash diverse rompono la semantica comune del merge;
- due parametri di precisione diversi restano recuperabili con normalizzazione.

Tesi centrale

Negli sketch count-distinct distribuiti, algoritmo, hash, seed e parametri fanno parte della semantica dello sketch: il merge è corretto solo entro questa semantica comune.

Conclusioni: contributi del lavoro

Software

Implementazione uniforme di più algoritmi count-distinct, con interfaccia comune per aggiornamento, stima, merge e reset.

Metodo

Framework riproducibile che separa dataset, hash, algoritmi, metriche e serializzazione e supporta streaming, merge omogeneo e merge eterogeneo.

Risultato principale

Distinzione operativa tra casi `valid`, `recoverable` e `invalid`, con evidenza sperimentale sulle condizioni del merge.

Contributo complessivo

Il lavoro non si limita a confrontare gli algoritmi di sketch ma esplicita quando il merge distribuito sia semanticamente corretto, quando vada rifiutato e quando richieda una trasformazione preliminare definita.

I risultati chiariscono bene il problema semantico di base, ma non esauriscono ancora la varietà dei flussi reali e delle topologie distribuite.

Dataset

La valutazione usa soprattutto un dataset sintetico controllato, utile per isolare i fenomeni ma non sufficiente da solo a rappresentare tutti i carichi reali.

Topologia

Lo studio del merge si concentra su casi pairwise, che chiariscono la semantica del problema ma non coprono catene o alberi di aggregazione più ampi.

Assi osservati

I casi eterogenei osservati sono due assi mirati (`hash mismatch`, `precision mismatch`) e il merge è sviluppato soprattutto su HLL++ come riferimento principale.

Dati reali

Portare il framework su dataset reali o su sorgenti di flusso come Apache Kafka, per osservare gli algoritmi fuori dal solo contesto sintetico.

Topologie e costi

Studiare topologie di merge più ampie e il punto ottimale in cui ridurre alla precisione minima, misurando anche costo di normalizzazione e merge.

Nuovi sketch

Estendere il framework ad algoritmi count-distinct più recenti (per esempio UltraLogLog) e, più avanti, ad altre famiglie di sketch.

Stesso principio

Le estensioni future hanno senso soprattutto lungo assi di eterogeneità la cui interpretazione semantica sia chiara, come in questo lavoro.

Grazie per l'attenzione.
Domande?